



AUTOENCODERS DETERMINÍSTICOS

Asignatura – Redes De Neuronas

Descripción breve

El objetivo de este proyecto es implementar un autoencoder profundo determinístico sobre los

conjuntos de datos MNIST y Fashion-MNIST (FMNIST).

En este documento se muestran los anexos de los resultados obtenidos en los diferentes
experimentos probados.

Adriana García, Sara Marianova y Sara Suárez

Tabla de contenido

ANEXO A: RESULTADOS GRIDSEARCH CNN (CONVOLUTIONAL NEURAL NETWORK) AUTOENCODER.....	- 4 -
A.1 GRIDSEARCH EN MNIST CON 3 CAPAS	- 4 -
A.2 GRIDSEARCH EN MNIST CON 5 CAPAS	- 6 -
A.3 GRIDSEARCH EN FMNIST CON 3 CAPAS	- 8 -
A.4 GRIDSEARCH EN FMNIST CON 5 CAPAS	- 10 -
ANEXO B: RESULTADOS GRIDSEARCH MLP (MULTI LAYER PERCEPTRON).....	- 13 -
B.1 GRIDSEARCH CON MNIST	- 13 -
B.2 GRIDSEARCH CON FMNIST	- 15 -
ANEXO C: DENOISING AUTOENCODER	- 18 -
C.1 DENOISING AUTOENCODER CON 3 CAPAS PARA MNIST.....	- 18 -
C.1.1 Curva PSNR contra σ	- 18 -
C.1.2 Ejemplos.....	- 18 -
C.2 DENOISING AUTOENCODER CON 5 CAPAS PARA MNIST.....	- 18 -
C.2.1 Curva PSNR contra σ	- 19 -
C.2.2 Ejemplos.....	- 19 -
C.3 DENOISING AUTOENCODER CON 3 CAPAS PARA FMNIST.....	- 19 -
C.3.1 Curva PSNR contra σ	- 19 -
C.3.2 Ejemplos.....	- 20 -
C.4 DENOISING AUTOENCODER CON 5 CAPAS PARA FMNIST.....	- 20 -
C.4.1 Curva PSNR contra σ	- 20 -
C.4.2 Ejemplos.....	- 20 -
C.5 DENOISING AUTOENCODER CON MLP PARA MNIST	- 20 -
C.5.1 Curva PSNR contra σ	- 21 -
C.5.2 Ejemplos.....	- 21 -
C.6 DENOISING AUTOENCODER CON MLP PARA FMNIST	- 21 -
C.6.1 Curva PSNR contra σ	- 21 -
C.6.2 Ejemplos.....	- 22 -
ANEXO D: EMBEDDINGS CON T-SNE Y PCA.....	- 23 -
D.1 ARQUITECTURA DE 3 CAPAS CON MNIST	- 23 -
D.1.1 t-SNE (MNIST 3L)	- 23 -
D.1.2 PCA (MNIST 3L).....	- 23 -
D.2 ARQUITECTURA DE 5 CAPAS CON MNIST	- 24 -
D.2.1 t-SNE (MNIST 5L)	- 24 -
D.2.2 PCA (MNIST 5L).....	- 24 -
D.3 ARQUITECTURA DE 3 CAPAS CON FMNIST	- 24 -
D.3.1 t-SNE (FMNIST 3L)	- 24 -
D.3.2 PCA (FMNIST 3L).....	- 25 -
D.4 ARQUITECTURA DE 5 CAPAS CON FMNIST	- 25 -
D.4.1 t-SNE (FMNIST 5L)	- 25 -
D.4.2 PCA (FMNIST 5L).....	- 25 -
D.5 ARQUITECTURA DE MLP CON MNIST	- 26 -
D.5.1 t-SNE (MNIST MLP)	- 26 -
D.5.2 PCA (MNIST MLP).....	- 26 -

D.6 ARQUITECTURA DE MLP CON FMNIST	- 26 -
D.6.1 <i>t-SNE (FMNIST MLP)</i>	- 26 -
D.6.2 <i>PCA (FMNIST MLP)</i>	- 27 -

ANEXO E: COMPARATIVA DE MEJORES Y PEORES RECONSTRUCCIONES DE LAS IMÁGENES SIN RUIDO..... - 28 -

E.1 ARQUITECTURA DE 3 CAPAS CON MNIST	- 28 -
E.1.1 <i>Mejores reconstrucciones</i>	- 28 -
E.1.2 <i>Peores Reconstrucciones</i>	- 28 -
E.2 ARQUITECTURA DE 5 CAPAS CON MNIST	- 28 -
E.2.1 <i>Mejores reconstrucciones</i>	- 28 -
E.2.2 <i>Peores Reconstrucciones</i>	- 29 -
E.3 ARQUITECTURA DE 3 CAPAS CON FMNIST	- 29 -
E.3.1 <i>Mejores reconstrucciones</i>	- 29 -
E.3.2 <i>Peores Reconstrucciones</i>	- 29 -
E.4 ARQUITECTURA DE 5 CAPAS CON FMNIST	- 30 -
E.4.1 <i>Mejores reconstrucciones</i>	- 30 -
E.4.2 <i>Peores Reconstrucciones</i>	- 30 -
E.5 ARQUITECTURA DE MLP CON MNIST	- 30 -
E.5.1 <i>Mejores reconstrucciones</i>	- 30 -
E.5.2 <i>Peores Reconstrucciones</i>	- 31 -
E.6 ARQUITECTURA DE MLP CON FMNIST	- 31 -
E.6.1 <i>Mejores reconstrucciones</i>	- 31 -
E.6.2 <i>Peores Reconstrucciones</i>	- 31 -

ANEXO F: COMPARATIVA DE MEJORES Y PEORES RECONSTRUCCIONES DE LAS IMÁGENES CON RUIDO..... - 32 -

F.1 ARQUITECTURA DE 3 CAPAS CON MNIST	- 32 -
F.1.1 <i>Mejores reconstrucciones</i>	- 32 -
F.1.2 <i>Peores Reconstrucciones</i>	- 32 -
F.2 ARQUITECTURA DE 5 CAPAS CON MNIST	- 32 -
F.2.1 <i>Mejores reconstrucciones</i>	- 32 -
F.2.2 <i>Peores Reconstrucciones</i>	- 33 -
F.3 ARQUITECTURA DE 3 CAPAS CON FMNIST	- 33 -
F.3.1 <i>Mejores reconstrucciones</i>	- 33 -
F.3.2 <i>Peores Reconstrucciones</i>	- 33 -
F.4 ARQUITECTURA DE 5 CAPAS CON FMNIST	- 34 -
F.4.1 <i>Mejores reconstrucciones</i>	- 34 -
F.4.2 <i>Peores Reconstrucciones</i>	- 34 -
F.5 ARQUITECTURA DE MLP CON MNIST	- 34 -
F.5.1 <i>Mejores reconstrucciones</i>	- 34 -
F.5.2 <i>Peores Reconstrucciones</i>	- 35 -
F.6 ARQUITECTURA DE MLP CON FMNIST	- 35 -
F.6.1 <i>Mejores reconstrucciones</i>	- 35 -
F.6.2 <i>Peores Reconstrucciones</i>	- 35 -

ANEXO G: ENTRENAMIENTO CRUZADO (MNIST → FMNIST Y FMNIST → MNIST) - 36 -

G.1 ENTRENAMIENTO CRUZADO CON LA ARQUITECTURA CONVOLUCIONAL DEL AUTOENCODER	- 36 -
G.2 ENTRENAMIENTO CRUZADO CON LA ARQUITECTURA MLP DEL AUTOENCODER	- 36 -

ANEXO H: USO DEL DECODER COMO GENERADOR DE IMÁGENES - 37 -

H.1 IMÁGENES SINTETIZADAS A PARTIR DE RUIDO GAUSSIANO ESTÁNDAR	- 37 -
<i>H.1.1 Arquitectura de 3 capas con MNIST.....</i>	- 37 -
<i>H.1.2 Arquitectura de 3 capas con FNIST.....</i>	- 37 -
<i>H.1.3 Arquitectura de 5 capas con MNIST.....</i>	- 38 -
<i>H.1.4 Arquitectura de 5 capas con FMNIST.....</i>	- 38 -
<i>H.1.5 Arquitectura de MLP con MNIST.....</i>	- 38 -
<i>H.1.6 Arquitectura de MLP con FMNIST.....</i>	- 38 -
H.2 IMÁGENES SINTETIZADAS DESDE LA GAUSSIANA LATENTE APRENDIDA.....	- 39 -
<i>H.2.1 Arquitectura de 3 capas con MNIST.....</i>	- 39 -
<i>H.2.2 Arquitectura de 3 capas con FMNIST.....</i>	- 39 -
<i>H.2.3 Arquitectura de 5 capas con MNIST.....</i>	- 39 -
<i>H.2.4 Arquitectura de 5 capas con FMNIST.....</i>	- 40 -
<i>H.2.5 Arquitectura de MLP con MNIST.....</i>	- 40 -
<i>H.2.6 Arquitectura de MLP con FMNIST.....</i>	- 40 -

Anexo A: Resultados GridSearch CNN (Convolutional Neural Network) Autoencoder

En este anexo, se presentan las tablas con las diferentes combinaciones del gridsearch y la métrica de error para cada una de estas. Las tablas están ordenadas de mayor a menor valor en la métrica, es decir, del mejor al peor modelo.

A.1 GridSearch en MNIST con 3 Capas

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
3L	600	0,001	0,001	0	30	31,97
3L	600	0,001	0	0	30	31,94
3L	600	0,001	0,0001	0	30	31,77
3L	300	0,001	0,0001	0	30	31,68
3L	300	0,001	0,001	0	30	31,65
3L	300	0,001	0	0	30	31,59
3L	600	0,0001	0	0	30	31,51
3L	600	0,0001	0,001	0	30	30,41
3L	600	0,0001	0,0001	0	30	30,24
3L	100	0,001	0,0001	0	30	29,92
3L	100	0,001	0,001	0	30	29,71
3L	100	0,001	0	0	30	29,70
3L	300	0,0001	0	0	30	29,67
3L	300	0,0001	0,0001	0	30	29,67
3L	300	0,0001	0,001	0	30	29,32
3L	100	0,0001	0,001	0	30	28,04
3L	300	0,001	0,0001	0,1	30	27,94
3L	600	0,001	0,001	0,1	30	27,94
3L	600	0,001	0,0001	0,1	30	27,90
3L	100	0,0001	0	0	30	27,87
3L	300	0,001	0	0,1	30	27,79
3L	100	0,0001	0,0001	0	30	27,78
3L	600	0,001	0	0,1	30	27,63
3L	300	0,001	0,001	0,1	30	27,59
3L	100	0,001	0	0,1	30	27,41
3L	100	0,001	0,0001	0,1	30	27,34
3L	50	0,001	0	0	30	27,32
3L	50	0,001	0,0001	0	30	27,28
3L	600	0,0001	0	0,1	30	27,23
3L	100	0,001	0,001	0,1	30	27,23
3L	600	0,0001	0,0001	0,1	30	27,19
3L	50	0,001	0,001	0	30	27,19
3L	600	0,0001	0,001	0,1	30	27,18
3L	300	0,0001	0	0,1	30	26,90
3L	300	0,0001	0,0001	0,1	30	26,88
3L	300	0,0001	0,001	0,1	30	26,84
3L	100	0,0001	0,0001	0,1	30	26,23
3L	100	0,0001	0	0,1	30	26,18
3L	100	0,0001	0,001	0,1	30	26,15
3L	50	0,0001	0,001	0	30	25,99
3L	50	0,0001	0	0	30	25,92
3L	50	0,0001	0,0001	0	30	25,90
3L	50	0,001	0	0,1	30	25,87

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
3L	50	0,001	0,0001	0,1	30	25,81
3L	50	0,001	0,001	0,1	30	25,69
3L	50	0,0001	0,001	0,1	30	25,19
3L	300	0,001	0	0,3	30	25,17
3L	600	0,001	0,0001	0,3	30	25,14
3L	300	0,001	0,001	0,3	30	25,12
3L	600	0,001	0	0,3	30	25,12
3L	50	0,0001	0,0001	0,1	30	25,12
3L	600	0,001	0,001	0,3	30	25,09
3L	50	0,0001	0	0,1	30	25,04
3L	300	0,001	0,0001	0,3	30	24,99
3L	100	0,001	0,0001	0,3	30	24,96
3L	30	0,001	0	0	30	24,96
3L	100	0,001	0	0,3	30	24,90
3L	30	0,001	0,001	0	30	24,84
3L	100	0,001	0,001	0,3	30	24,83
3L	600	0,0001	0	0,3	30	24,69
3L	600	0,0001	0,0001	0,3	30	24,65
3L	600	0,0001	0,001	0,3	30	24,56
3L	30	0,001	0,0001	0	30	24,52
3L	300	0,0001	0	0,3	30	24,49
3L	300	0,0001	0,001	0,3	30	24,49
3L	300	0,0001	0,0001	0,3	30	24,42
3L	50	0,001	0,0001	0,3	30	24,12
3L	100	0,0001	0	0,3	30	24,11
3L	30	0,001	0,0001	0,1	30	24,10
3L	30	0,001	0	0,1	30	24,09
3L	50	0,001	0	0,3	30	24,08
3L	100	0,0001	0,001	0,3	30	24,06
3L	100	0,0001	0,0001	0,3	30	24,06
3L	30	0,001	0,001	0,1	30	24,03
3L	50	0,001	0,001	0,3	30	23,94
3L	30	0,0001	0,0001	0	30	23,93
3L	30	0,0001	0,001	0	30	23,84
3L	30	0,0001	0	0	30	23,84
3L	50	0,0001	0,0001	3	30	23,58
3L	30	0,0001	0,0001	0,1	30	23,53
3L	50	0,0001	0	0,3	30	23,52
3L	50	0,0001	0,001	0,3	30	23,45
3L	30	0,0001	0,001	0,1	30	23,45
3L	30	0,0001	0	0,1	30	23,41
3L	30	0,001	0,0001	0,3	30	22,93
3L	30	0,001	0,001	0,3	30	22,89
3L	30	0,001	0	0,3	30	22,88
3L	30	0,0001	0	0,3	30	22,40
3L	30	0,0001	0,0001	0,3	30	22,35
3L	30	0,0001	0,001	0,3	30	22,33
3L	15	0,001	0,0001	0	30	21,85
3L	15	0,001	0,001	0	30	21,74
3L	15	0,001	0	0	30	21,55
3L	15	0,001	0	0,1	30	21,43
3L	15	0,001	0,001	0,1	30	21,36

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
3L	15	0,001	0,0001	0,1	30	21,24
3L	15	0,0001	0,0001	0	30	21,08
3L	15	0,0001	0	0	30	21,07
3L	15	0,0001	0,001	0,1	30	20,96
3L	15	0,0001	0,001	0	30	20,92
3L	15	0,0001	0,0001	0,1	30	20,90
3L	15	0,0001	0	0,1	30	20,83
3L	15	0,001	0,0001	0,3	30	20,57
3L	15	0,001	0,001	0,3	30	20,51
3L	15	0,001	0	0,3	30	20,47
3L	15	0,0001	0,001	0,3	30	20,28
3L	15	0,0001	0	0,3	30	20,21
3L	15	0,0001	0,0001	0,3	30	20,15

A.2 GridSearch en MNIST con 5 Capas

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	600	0,0001	0,001	0	40	28,74
5L	600	0,0001	0,0001	0	40	28,61
5L	600	0,0001	0	0	40	28,57
5L	300	0,0001	0	0	40	28,50
5L	300	0,0001	0,001	0	40	28,25
5L	300	0,001	0,0001	0	40	28,16
5L	100	0,001	0,001	0	40	28,14
5L	300	0,001	0,001	0	40	28,14
5L	600	0,001	0,001	0	40	28,13
5L	300	0,0001	0,0001	0	40	28,02
5L	100	0,0001	0	0	40	27,84
5L	300	0,001	0	0	40	27,81
5L	100	0,0001	0,0001	0	40	27,78
5L	600	0,001	0,0001	0	40	27,75
5L	100	0,001	0	0	40	27,65
5L	100	0,001	0,0001	0	40	27,58
5L	600	0,001	0	0	40	27,55
5L	100	0,0001	0,001	0	40	27,23
5L	50	0,001	0,0001	0	40	27,17
5L	50	0,001	0	0	40	26,95
5L	50	0,001	0,001	0	40	26,86
5L	50	0,0001	0	0	40	26,22
5L	300	0,0001	0,0001	0,1	40	25,95
5L	300	0,001	0,0001	0,1	40	25,95
5L	600	0,0001	0,0001	0,1	40	25,90
5L	600	0,0001	0	0,1	40	25,88
5L	300	0,001	0,001	0,1	40	25,88
5L	600	0,001	0,0001	0,1	40	25,84
5L	300	0,0001	0	0,1	40	25,83
5L	600	0,0001	0,001	0,1	40	25,83
5L	300	0,001	0	0,1	40	25,81
5L	100	0,001	0,001	0,1	40	25,76
5L	600	0,001	0,001	0,1	40	25,75
5L	100	0,001	0,0001	0,1	40	25,74

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	50	0,0001	0,0001	0	40	25,68
5L	600	0,001	0	0,1	40	25,68
5L	100	0,0001	0	0,1	40	25,67
5L	30	0,001	0	0	40	25,57
5L	100	0,0001	0,0001	0,1	40	25,52
5L	100	0,001	0	0,1	40	25,51
5L	100	0,0001	0,001	0,1	40	25,47
5L	300	0,0001	0,001	0,1	40	25,46
5L	50	0,001	0	0,1	40	25,38
5L	30	0,001	0,0001	0	40	25,34
5L	50	0,001	0,0001	0,1	40	25,33
5L	30	0,001	0,001	0	40	25,22
5L	50	0,001	0,001	0,1	40	25,12
5L	50	0,0001	0,0001	0,1	40	25,00
5L	50	0,0001	0	0,1	40	24,99
5L	50	0,0001	0,001	0	40	24,86
5L	50	0,0001	0,001	0,1	40	24,80
5L	30	0,0001	0	0	40	24,49
5L	30	0,0001	0,0001	0	40	24,44
5L	30	0,001	0	0,1	40	24,41
5L	30	0,001	0,0001	0,1	40	24,21
5L	30	0,001	0,001	0,1	40	24,18
5L	30	0,0001	0,001	0	40	24,00
5L	30	0,0001	0	0,1	40	23,92
5L	30	0,0001	0,0001	0,1	40	23,79
5L	30	0,0001	0,001	0,1	40	23,77
5L	600	0,001	0,0001	0,3	40	23,65
5L	300	0,001	0	0,3	40	23,63
5L	300	0,001	0,001	0,3	40	23,59
5L	100	0,001	0	0,3	40	23,57
5L	300	0,001	0,0001	0,3	40	23,55
5L	100	0,001	0,0001	0,3	40	23,54
5L	600	0,001	0,001	0,3	40	23,52
5L	100	0,001	0,001	0,3	40	23,50
5L	600	0,001	0	0,3	40	23,48
5L	50	0,001	0	0,3	40	23,45
5L	50	0,001	0,0001	0,3	40	23,27
5L	300	0,0001	0	0,3	40	23,25
5L	300	0,0001	0,0001	0,3	40	23,24
5L	600	0,0001	0,0001	0,3	40	23,24
5L	600	0,0001	0	0,3	40	23,23
5L	600	0,0001	0,001	0,3	40	23,17
5L	300	0,0001	0,001	0,3	40	23,13
5L	100	0,0001	0	0,3	40	23,13
5L	50	0,001	0,001	0,3	40	23,08
5L	100	0,0001	0,001	0,3	40	23,02
5L	100	0,0001	0,0001	0,3	40	23,00
5L	50	0,0001	0,0001	0,3	40	22,96
5L	50	0,0001	0	0,3	40	22,91
5L	50	0,0001	0,001	0,3	40	22,90
5L	30	0,001	0	0,3	40	22,89
5L	30	0,001	0,0001	0,3	40	22,84

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	30	0,001	0,001	0,3	40	22,65
5L	15	0,001	0	0	40	22,61
5L	15	0,001	0,0001	0	40	22,57
5L	15	0,001	0,001	0	40	22,50
5L	30	0,0001	0,001	0,3	40	22,43
5L	30	0,0001	0	0,3	40	22,31
5L	30	0,0001	0,0001	0,3	40	22,09
5L	15	0,0001	0,0001	0	40	22,09
5L	15	0,001	0	0,1	40	22,09
5L	15	0,001	0,0001	0,1	40	22,08
5L	15	0,0001	0	0	40	21,98
5L	15	0,001	0,001	0,1	40	21,96
5L	15	0,0001	0	0,1	40	21,84
5L	15	0,0001	0,0001	0,1	40	21,84
5L	15	0,0001	0,001	0	40	21,80
5L	15	0,0001	0,001	0,1	40	21,70
5L	15	0,001	0	0,3	40	21,32
5L	15	0,001	0,0001	0,3	40	21,29
5L	15	0,001	0,001	0,3	40	21,08
5L	15	0,0001	0	0,3	40	20,97
5L	15	0,0001	0,0001	0,3	40	20,93
5L	15	0,0001	0,001	0,3	40	20,92

A.3 GridSearch en FMNIST con 3 Capas

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
3L	600	0,001	0,0001	0	30	28,57
3L	600	0,001	0,001	0	30	28,56
3L	600	0,001	0	0	30	28,39
3L	300	0,001	0,001	0	30	27,53
3L	300	0,001	0	0	30	27,44
3L	300	0,001	0,0001	0	30	27,38
3L	600	0,0001	0,0001	0	30	26,20
3L	600	0,0001	0,001	0	30	26,08
3L	600	0,0001	0	0	30	25,87
3L	600	0,001	0,0001	0,1	30	25,13
3L	300	0,0001	0,001	0	30	25,05
3L	300	0,0001	0,0001	0	30	25,02
3L	600	0,001	0,001	0,1	30	24,99
3L	600	0,001	0	0,1	30	24,95
3L	300	0,0001	0	0	30	24,95
3L	300	0,001	0	0,1	30	24,83
3L	300	0,001	0,001	0,1	30	24,80
3L	300	0,001	0,0001	0,1	30	24,78
3L	100	0,001	0	0	30	24,25
3L	100	0,001	0,0001	0	30	24,16
3L	600	0,0001	0	0,1	30	24,15
3L	600	0,0001	0,0001	0,1	30	24,13
3L	600	0,0001	0,001	0,1	30	24,06
3L	100	0,001	0,001	0	30	24,06

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
3L	300	0,0001	0	0,1	30	23,60
3L	300	0,0001	0,001	0,1	30	23,58
3L	300	0,0001	0,0001	0,1	30	23,55
3L	100	0,001	0	0,1	30	23,30
3L	100	0,001	0,0001	0,1	30	23,24
3L	100	0,0001	0,0001	0	30	23,21
3L	100	0,001	0,001	0,1	30	23,19
3L	100	0,0001	0,001	0	30	23,15
3L	100	0,0001	0	0	30	23,14
3L	50	0,001	0,0001	0	30	22,68
3L	50	0,001	0	0	30	22,57
3L	100	0,0001	0,001	0,1	30	22,56
3L	50	0,001	0,001	0	30	22,55
3L	300	0,001	0	0,3	30	22,50
3L	600	0,001	0,0001	0,3	30	22,50
3L	300	0,001	0,001	0,3	30	22,49
3L	600	0,001	0	0,3	30	22,45
3L	300	0,001	0,0001	0,3	30	22,45
3L	600	0,001	0,001	0,3	30	22,44
3L	100	0,0001	0	0,1	30	22,43
3L	100	0,0001	0,0001	0,1	30	22,43
3L	50	0,001	0	0,1	30	22,10
3L	50	0,001	0,0001	0,1	30	22,08
3L	600	0,0001	0,001	0,3	30	22,05
3L	50	0,001	0,001	0,1	30	22,01
3L	600	0,0001	0	0,3	30	21,99
3L	100	0,001	0	0,3	30	21,98
3L	100	0,001	0,001	0,3	30	21,96
3L	600	0,0001	0,0001	0,3	30	21,94
3L	50	0,0001	0,001	0	30	21,93
3L	50	0,0001	0	0	30	21,92
3L	50	0,0001	0,0001	0	30	21,90
3L	100	0,001	0,0001	0,3	30	21,86
3L	300	0,0001	0,0001	0,3	30	21,75
3L	300	0,0001	0,001	0,3	30	21,74
3L	300	0,0001	0	0,3	30	21,73
3L	30	0,001	0	0	30	21,65
3L	30	0,001	0,0001	0	30	21,62
3L	30	0,001	0,001	0	30	21,59
3L	50	0,0001	0,001	0,1	30	21,59
3L	50	0,0001	0,0001	0,1	30	21,55
3L	50	0,0001	0	0,1	30	21,47
3L	30	0,001	0,0001	0,1	30	21,27
3L	100	0,0001	0,001	0,3	30	21,26
3L	30	0,001	0	0,1	30	21,25
3L	50	0,001	0,0001	0,3	30	21,22
3L	100	0,0001	0,0001	0,3	30	21,22
3L	30	0,001	0,001	0,1	30	21,22
3L	50	0,001	0	0,3	30	21,21
3L	50	0,001	0,001	0,3	30	21,18
3L	30	0,0001	0	0	30	21,12

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
3L	100	0,0001	0	0,3	30	21,10
3L	30	0,0001	0,0001	0	30	21,09
3L	30	0,0001	0,001	0	30	21,04
3L	30	0,0001	0,001	0,1	30	20,85
3L	30	0,0001	0	0,1	30	20,82
3L	30	0,0001	0,0001	0,1	30	20,78
3L	50	0,0001	0,001	0,3	30	20,74
3L	50	0,0001	0,0001	0,3	30	20,70
3L	50	0,0001	0	0,3	30	20,65
3L	30	0,001	0,0001	0,3	30	20,59
3L	30	0,001	0,001	0,3	30	20,58
3L	30	0,001	0	0,3	30	20,56
3L	15	0,001	0	0	30	20,36
3L	15	0,001	0,001	0	30	20,34
3L	15	0,001	0,0001	0	30	20,33
3L	30	0,0001	0,001	0,3	30	20,17
3L	30	0,0001	0,0001	0,3	30	20,15
3L	15	0,001	0,0001	0,1	30	20,15
3L	30	0,0001	0	0,3	30	20,13
3L	15	0,001	0	0,1	30	20,09
3L	15	0,001	0,001	0,1	30	20,07
3L	15	0,0001	0	0	30	19,97
3L	15	0,0001	0,0001	0	30	19,91
3L	15	0,0001	0,001	0	30	19,90
3L	15	0,0001	0,001	0,1	30	19,80
3L	15	0,0001	0	0,1	30	19,75
3L	15	0,0001	0,0001	0,1	30	19,75
3L	15	0,001	0,0001	0,3	30	19,68
3L	15	0,001	0	0,3	30	19,68
3L	15	0,001	0,001	0,3	30	19,66
3L	15	0,0001	0,0001	0,3	30	19,35
3L	15	0,0001	0,001	0,3	30	19,31
3L	15	0,0001	0	0,3	30	19,29

A.4 GridSearch en FMNIST con 5 Capas

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	600	0,0001	0,001	0	30	24,57
5L	600	0,0001	0	0	30	24,55
5L	600	0,0001	0,0001	0	30	24,30
5L	300	0,0001	0,0001	0	30	24,16
5L	300	0,0001	0	0	30	24,08
5L	300	0,0001	0,001	0	30	24,02
5L	300	0,001	0,001	0	30	23,89
5L	600	0,001	0,001	0	30	23,82
5L	600	0,001	0,0001	0	30	23,48
5L	300	0,001	0,0001	0	30	23,44
5L	100	0,001	0,001	0	30	23,36
5L	600	0,001	0	0	30	23,28
5L	100	0,001	0,0001	0	30	23,26

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	300	0,001	0	0	30	23,26
5L	100	0,0001	0	0	30	23,14
5L	100	0,0001	0,0001	0	30	23,12
5L	100	0,0001	0,001	0	30	23,10
5L	100	0,001	0	0	30	23,02
5L	50	0,001	0,0001	0	30	22,67
5L	600	0,0001	0	0,1	30	22,65
5L	600	0,0001	0,001	0,1	30	22,63
5L	50	0,001	0	0	30	22,63
5L	300	0,001	0,001	0,1	30	22,62
5L	50	0,001	0,001	0	30	22,58
5L	600	0,001	0,001	0,1	30	22,57
5L	600	0,0001	0,0001	0,1	30	22,57
5L	300	0,0001	0	0,1	30	22,48
5L	300	0,001	0,0001	0,1	30	22,46
5L	600	0,001	0,0001	0,1	30	22,45
5L	300	0,0001	0,0001	0,1	30	22,41
5L	100	0,001	0,0001	0,1	30	22,37
5L	300	0,0001	0,001	0,1	30	22,34
5L	100	0,001	0,001	0,1	30	22,29
5L	50	0,0001	0,0001	0	30	22,22
5L	100	0,001	0	0,1	30	22,21
5L	50	0,0001	0	0	30	22,21
5L	600	0,001	0	0,1	30	22,21
5L	100	0,0001	0,0001	0,1	30	22,08
5L	100	0,0001	0	0,1	30	22,08
5L	50	0,0001	0,001	0	30	22,07
5L	300	0,001	0	0,1	30	22,05
5L	100	0,0001	0,001	0,1	30	22,02
5L	50	0,001	0,0001	0,1	30	21,94
5L	30	0,001	0	0	30	21,91
5L	50	0,001	0	0,1	30	21,88
5L	30	0,001	0,0001	0	30	21,85
5L	50	0,001	0,001	0,1	30	21,78
5L	30	0,001	0,001	0	30	21,67
5L	50	0,0001	0	0,1	30	21,61
5L	50	0,0001	0,0001	0,1	30	21,59
5L	50	0,0001	0,001	0,1	30	21,47
5L	30	0,0001	0	0	30	21,46
5L	30	0,0001	0,0001	0	30	21,43
5L	30	0,001	0,0001	0,1	30	21,33
5L	30	0,0001	0,001	0	30	21,32
5L	30	0,001	0	0,1	30	21,29
5L	30	0,001	0,001	0,1	30	21,26
5L	600	0,001	0,001	0,3	30	21,11
5L	300	0,001	0,001	0,3	30	21,10
5L	300	0,001	0,0001	0,3	30	21,08
5L	600	0,001	0,0001	0,3	30	21,04
5L	30	0,0001	0,0001	0,1	30	21,04
5L	100	0,001	0,001	0,3	30	21,03
5L	100	0,001	0,0001	0,3	30	21,03
5L	30	0,0001	0,001	0,1	30	21,00

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR (db)
5L	300	0,001	0	0,3	30	20,95
5L	30	0,0001	0	0,1	30	20,94
5L	600	0,001	0	0,3	30	20,93
5L	100	0,001	0	0,3	30	20,89
5L	50	0,001	0,0001	0,3	30	20,87
5L	600	0,0001	0,001	0,3	30	20,83
5L	600	0,0001	0,0001	0,3	30	20,83
5L	50	0,001	0	0,3	30	20,83
5L	50	0,001	0,001	0,3	30	20,79
5L	300	0,0001	0,001	0,3	30	20,75
5L	300	0,0001	0	0,3	30	20,70
5L	15	0,001	0,0001	0	30	20,68
5L	300	0,0001	0,0001	0,3	30	20,68
5L	15	0,001	0	0	30	20,66
5L	15	0,001	0,001	0	30	20,63
5L	30	0,001	0,0001	0,3	30	20,60
5L	100	0,0001	0	0,3	30	20,60
5L	30	0,001	0	0,3	30	20,56
5L	600	0,0001	0	0,3	30	20,55
5L	100	0,0001	0,0001	0,3	30	20,55
5L	100	0,0001	0,001	0,3	30	20,51
5L	30	0,001	0,001	0,3	30	20,49
5L	50	0,0001	0,001	0,3	30	20,45
5L	50	0,0001	0,0001	0,3	30	20,43
5L	15	0,001	0	0,1	30	20,42
5L	15	0,001	0,0001	0,1	30	20,41
5L	15	0,001	0,001	0,1	30	20,39
5L	50	0,0001	0	0,3	30	20,38
5L	15	0,0001	0	0	30	20,38
5L	15	0,0001	0,0001	0	30	20,36
5L	15	0,0001	0,001	0	30	20,28
5L	30	0,0001	0,0001	0,3	30	20,15
5L	15	0,0001	0	0,1	30	20,14
5L	15	0,0001	0,0001	0,1	30	20,14
5L	30	0,0001	0	0,3	30	20,14
5L	30	0,0001	0,001	0,3	30	20,14
5L	15	0,0001	0,001	0,1	30	20,05
5L	15	0,001	0	0,3	30	19,92
5L	15	0,001	0,0001	0,3	30	19,89
5L	15	0,001	0,001	0,3	30	19,84
5L	15	0,0001	0	0,3	30	19,56
5L	15	0,0001	0,0001	0,3	30	19,56
5L	15	0,0001	0,001	0,3	30	19,52

Anexo B: Resultados GridSearch MLP (Multi Layer Perceptron)

En este anexo, se presentan las tablas con las diferentes combinaciones del gridsearch y la métrica de error para cada una de estas. Las tablas están ordenadas de mayor a menor valor en la métrica, es decir, del mejor al peor modelo.

B.1 GridSearch con MNIST

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	600	0,001	0,001	0	30	26,07
MLP	600	0,001	0,0001	0	30	25,91
MLP	300	0,001	0,001	0	30	25,83
MLP	300	0,001	0,0001	0	30	25,69
MLP	600	0,001	0	0	30	25,65
MLP	300	0,001	0	0	30	25,51
MLP	100	0,001	0,001	0	30	25,33
MLP	100	0,001	0	0	30	25,20
MLP	100	0,001	0,0001	0	30	25,17
MLP	50	0,001	0,0001	0	30	25,03
MLP	50	0,001	0	0	30	25,01
MLP	50	0,001	0,001	0	30	24,91
MLP	30	0,001	0	0	30	24,10
MLP	30	0,001	0,001	0	30	24,08
MLP	30	0,001	0,0001	0	30	24,06
MLP	600	0,0001	0,001	0	30	23,54
MLP	600	0,0001	0,0001	0	30	23,15
MLP	300	0,0001	0,001	0	30	23,07
MLP	100	0,0001	0,001	0	30	22,70
MLP	300	0,0001	0,0001	0	30	22,68
MLP	600	0,0001	0	0	30	22,66
MLP	600	0,001	0,001	0,1	30	22,57
MLP	50	0,0001	0,001	0	30	22,56
MLP	600	0,001	0,0001	0,1	30	22,53
MLP	300	0,001	0	0,1	30	22,50
MLP	300	0,001	0,0001	0,1	30	22,49
MLP	600	0,001	0	0,1	30	22,47
MLP	300	0,001	0,001	0,1	30	22,47
MLP	100	0,001	0,001	0,1	30	22,44
MLP	100	0,001	0	0,1	30	22,44
MLP	100	0,0001	0,0001	0	30	22,41
MLP	50	0,001	0,0001	0,1	30	22,40
MLP	30	0,0001	0,001	0	30	22,39
MLP	300	0,0001	0	0	30	22,38
MLP	100	0,001	0,0001	0,1	30	22,38
MLP	50	0,001	0,001	0,1	30	22,29
MLP	30	0,001	0,0001	0,1	30	22,24
MLP	50	0,001	0	0,1	30	22,23
MLP	50	0,0001	0,0001	0	30	22,21
MLP	30	0,001	0,001	0,1	30	22,15
MLP	30	0,001	0	0,1	30	22,12
MLP	100	0,0001	0	0	30	22,07
MLP	30	0,0001	0,0001	0	30	22,06
MLP	15	0,001	0	0	30	21,84

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	15	0,001	0,0001	0	30	21,84
MLP	50	0,0001	0	0	30	21,82
MLP	15	0,001	0,001	0	30	21,76
MLP	600	0,0001	0,001	0,1	30	21,68
MLP	600	0,0001	0	0,1	30	21,65
MLP	600	0,0001	0,0001	0,1	30	21,64
MLP	300	0,0001	0,001	0,1	30	21,48
MLP	300	0,0001	0	0,1	30	21,48
MLP	300	0,0001	0,0001	0,1	30	21,46
MLP	30	0,0001	0	0	30	21,42
MLP	50	0,0001	0,001	0,1	30	21,35
MLP	100	0,0001	0,001	0,1	30	21,34
MLP	50	0,0001	0,0001	0,1	30	21,34
MLP	100	0,0001	0,0001	0,1	30	21,32
MLP	100	0,0001	0	0,1	30	21,30
MLP	50	0,0001	0	0,1	30	21,25
MLP	30	0,0001	0,0001	0,1	30	21,23
MLP	30	0,0001	0	0,1	30	21,22
MLP	30	0,0001	0,001	0,1	30	21,20
MLP	15	0,001	0	0,1	30	21,10
MLP	15	0,001	0,0001	0,1	30	20,97
MLP	15	0,001	0,001	0,1	30	20,93
MLP	15	0,0001	0,001	0	30	20,63
MLP	15	0,0001	0	0,1	30	20,62
MLP	15	0,0001	0,0001	0	30	20,59
MLP	15	0,0001	0,0001	0,1	30	20,57
MLP	15	0,0001	0,001	0,1	30	20,47
MLP	15	0,0001	0	0	30	20,36
MLP	300	0,001	0,001	0,3	30	20,22
MLP	50	0,001	0	0,3	30	20,21
MLP	100	0,001	0,0001	0,3	30	20,18
MLP	100	0,001	0,001	0,3	30	20,18
MLP	300	0,001	0	0,3	30	20,17
MLP	50	0,001	0,0001	0,3	30	20,16
MLP	50	0,001	0,001	0,3	30	20,16
MLP	100	0,001	0	0,3	30	20,14
MLP	600	0,001	0,001	0,3	30	20,12
MLP	300	0,001	0,0001	0,3	30	20,11
MLP	30	0,001	0	0,3	30	20,11
MLP	600	0,001	0	0,3	30	20,09
MLP	30	0,001	0,0001	0,3	30	20,09
MLP	600	0,001	0,0001	0,3	30	20,05
MLP	30	0,001	0,001	0,3	30	19,97
MLP	15	0,001	0	0,3	30	19,61
MLP	15	0,001	0,0001	0,3	30	19,60
MLP	15	0,001	0,001	0,3	30	19,54
MLP	600	0,0001	0	0,3	30	19,32
MLP	600	0,0001	0,001	0,3	30	19,31
MLP	600	0,0001	0,0001	0,3	30	19,31
MLP	300	0,0001	0,001	0,3	30	19,17
MLP	300	0,0001	0	0,3	30	19,12
MLP	100	0,0001	0	0,3	30	19,10

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	300	0,0001	0,0001	0,3	30	19,08
MLP	50	0,0001	0,001	0,3	30	19,07
MLP	100	0,0001	0,0001	0,3	30	19,06
MLP	50	0,0001	0,0001	0,3	30	19,06
MLP	30	0,0001	0,001	0,3	30	19,04
MLP	30	0,0001	0,0001	0,3	30	19,02
MLP	50	0,0001	0	0,3	30	18,98
MLP	15	0,0001	0	0,3	30	18,98
MLP	30	0,0001	0	0,3	30	18,97
MLP	100	0,0001	0,001	0,3	30	18,95
MLP	15	0,0001	0,001	0,3	30	18,86
MLP	15	0,0001	0,0001	0,3	30	18,85

B.2 GridSearch con FMNIST

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	600	0,001	0,001	0	30	23,32
MLP	300	0,001	0,0001	0	30	23,18
MLP	600	0,001	0	0	30	23,16
MLP	600	0,001	0,0001	0	30	23,15
MLP	300	0,001	0,001	0	30	23,12
MLP	300	0,001	0	0	30	23,06
MLP	100	0,001	0,001	0	30	22,93
MLP	100	0,001	0	0	30	22,86
MLP	100	0,001	0,0001	0	30	22,85
MLP	50	0,001	0,0001	0	30	22,61
MLP	50	0,001	0	0	30	22,61
MLP	50	0,001	0,001	0	30	22,39
MLP	30	0,001	0	0	30	22,14
MLP	30	0,001	0,0001	0	30	22,12
MLP	30	0,001	0,001	0	30	22,02
MLP	15	0,001	0,0001	0	30	21,18
MLP	15	0,001	0	0	30	21,17
MLP	15	0,001	0,001	0	30	21,08
MLP	50	0,001	0	0,1	30	21,00
MLP	100	0,001	0,0001	0,1	30	21,00
MLP	30	0,001	0	0,1	30	21,00
MLP	100	0,001	0	0,1	30	20,98
MLP	600	0,0001	0,001	0	30	20,96
MLP	100	0,001	0,001	0,1	30	20,96
MLP	600	0,001	0,001	0,1	30	20,94
MLP	300	0,001	0,0001	0,1	30	20,93
MLP	50	0,001	0,0001	0,1	30	20,92
MLP	30	0,001	0,0001	0,1	30	20,92
MLP	600	0,001	0,0001	0,1	30	20,90
MLP	300	0,001	0,001	0,1	30	20,87
MLP	600	0,001	0	0,1	30	20,86
MLP	50	0,001	0,001	0,1	30	20,85
MLP	30	0,001	0,001	0,1	30	20,85
MLP	300	0,001	0	0,1	30	20,83
MLP	300	0,0001	0,001	0	30	20,72

Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	15	0,001	0,0001	0,1	30	20,62
MLP	15	0,001	0	0,1	30	20,57
MLP	50	0,0001	0,001	0	30	20,56
MLP	100	0,0001	0,001	0	30	20,56
MLP	600	0,0001	0,0001	0	30	20,54
MLP	15	0,001	0,001	0,1	30	20,51
MLP	30	0,0001	0,001	0	30	20,51
MLP	300	0,0001	0,0001	0	30	20,45
MLP	100	0,0001	0,0001	0	30	20,43
MLP	50	0,0001	0,0001	0	30	20,38
MLP	30	0,0001	0,0001	0	30	20,38
MLP	600	0,0001	0	0	30	20,28
MLP	15	0,0001	0,001	0	30	20,18
MLP	15	0,0001	0,0001	0	30	20,16
MLP	50	0,0001	0	0	30	20,15
MLP	600	0,0001	0	0,1	30	20,12
MLP	300	0,0001	0	0	30	20,12
MLP	600	0,0001	0,0001	0,1	30	20,12
MLP	600	0,0001	0,001	0,1	30	20,11
MLP	30	0,0001	0	0	30	20,07
MLP	300	0,0001	0,001	0,1	30	20,06
MLP	50	0,0001	0	0,1	30	20,06
MLP	300	0,0001	0,0001	0,1	30	20,05
MLP	100	0,0001	0,0001	0,1	30	20,03
MLP	100	0,0001	0	0	30	20,03
MLP	300	0,0001	0	0,1	30	20,00
MLP	50	0,0001	0,0001	0,1	30	20,00
MLP	15	0,0001	0,0001	0,1	30	19,99
MLP	15	0,0001	0	0,1	30	19,98
MLP	30	0,0001	0	0,1	30	19,98
MLP	15	0,0001	0	0	30	19,97
MLP	30	0,0001	0,0001	0,1	30	19,96
MLP	100	0,0001	0	0,1	30	19,93
MLP	30	0,0001	0,001	0,1	30	19,93
MLP	100	0,0001	0,001	0,1	30	19,91
MLP	50	0,0001	0,001	0,1	30	19,90
MLP	15	0,0001	0,001	0,1	30	19,87
MLP	50	0,001	0	0,3	30	19,54
MLP	100	0,001	0,0001	0,3	30	19,53
MLP	30	0,001	0,0001	0,3	30	19,52
MLP	30	0,001	0	0,3	30	19,50
MLP	100	0,001	0	0,3	30	19,49
MLP	50	0,001	0,0001	0,3	30	19,49
MLP	30	0,001	0,001	0,3	30	19,44
MLP	15	0,001	0	0,3	30	19,42
MLP	300	0,001	0,0001	0,3	30	19,39
MLP	15	0,001	0,0001	0,3	30	19,39
MLP	50	0,001	0,001	0,3	30	19,39
MLP	300	0,001	0,001	0,3	30	19,38
MLP	100	0,001	0,001	0,3	30	19,37
MLP	300	0,001	0	0,3	30	19,35
MLP	15	0,001	0,001	0,3	30	19,27

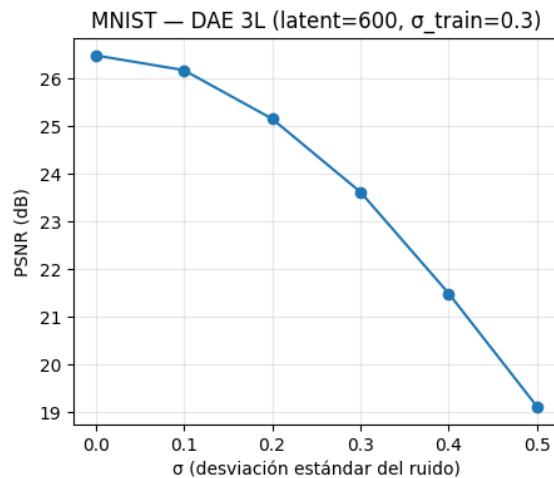
Arquitectura	Latent	Learning Rate	Lambda L1	Dropout	Epochs	PSNR
MLP	600	0,0001	0,001	0,3	30	19,06
MLP	600	0,0001	0	0,3	30	19,01
MLP	600	0,0001	0,0001	0,3	30	18,96
MLP	300	0,0001	0,001	0,3	30	18,90
MLP	600	0,001	0	0,3	30	18,89
MLP	300	0,0001	0,0001	0,3	30	18,89
MLP	300	0,0001	0	0,3	30	18,88
MLP	15	0,0001	0,0001	0,3	30	18,86
MLP	30	0,0001	0,0001	0,3	30	18,85
MLP	100	0,0001	0	0,3	30	18,83
MLP	15	0,0001	0	0,3	30	18,83
MLP	50	0,0001	0	0,3	30	18,83
MLP	50	0,0001	0,0001	0,3	30	18,82
MLP	30	0,0001	0	0,3	30	18,81
MLP	15	0,0001	0,001	0,3	30	18,80
MLP	100	0,0001	0,0001	0,3	30	18,80
MLP	600	0,001	0,001	0,3	30	18,78
MLP	30	0,0001	0,001	0,3	30	18,77
MLP	100	0,0001	0,001	0,3	30	18,75
MLP	50	0,0001	0,001	0,3	30	18,71
MLP	600	0,001	0,0001	0,3	30	18,42

Anexo C: Denoising Autoencoder

C.1 Denoising Autoencoder con 3 capas para MNIST

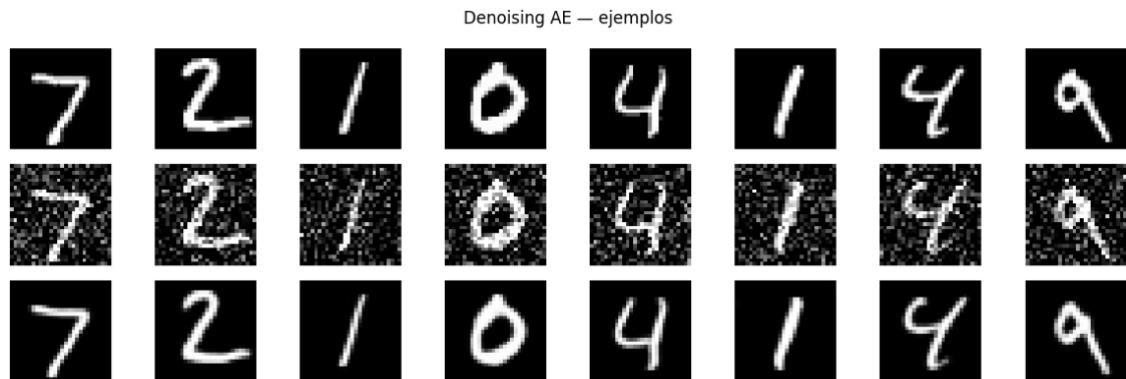
Se crea y entrena un denoising autoencoder (DAE) de 3 capas para MNIST partiendo de la mejor versión previa de un autoencoder (AE-3L).

C.1.1 Curva PSNR contra σ



C.1.2 Ejemplos

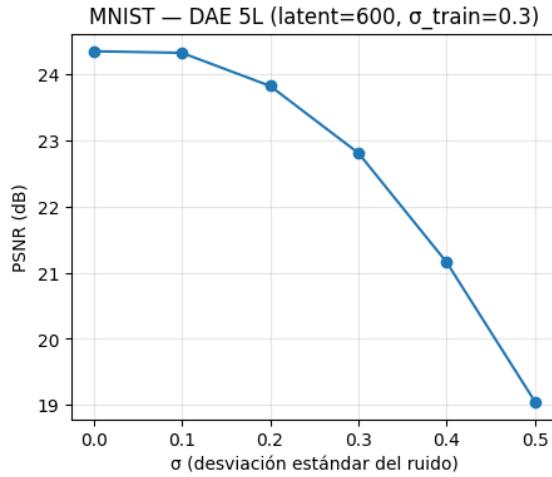
- Fila 1: imágenes limpias
- Fila 2: las mismas imágenes pero con ruido gaussiano.
- Fila 3: las salidas del denoising autoencoder en donde el modelo recupera la estructura de las imágenes.



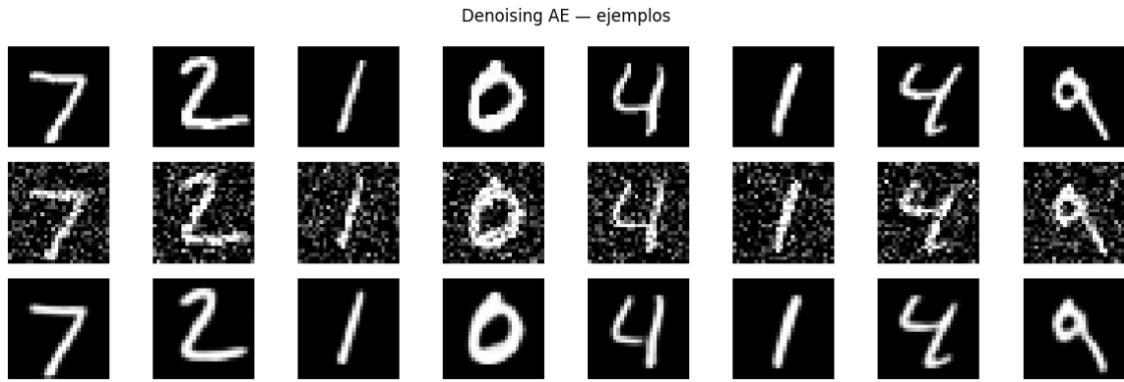
C.2 Denoising Autoencoder con 5 capas para MNIST

Se crea y entrena un denoising autoencoder (DAE) de 5 capas para MNIST partiendo de la mejor versión previa de un autoencoder (AE-5L).

C.2.1 Curva PSNR contra σ



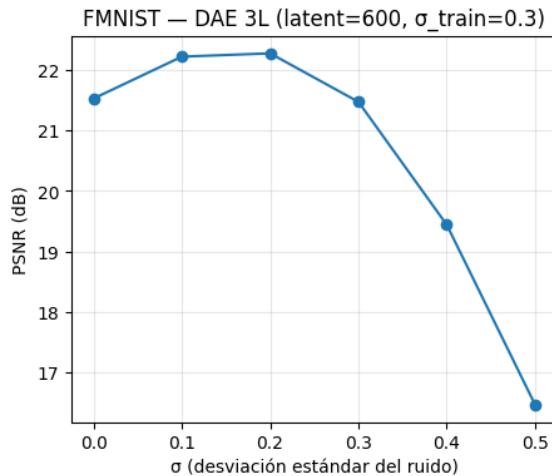
C.2.2 Ejemplos



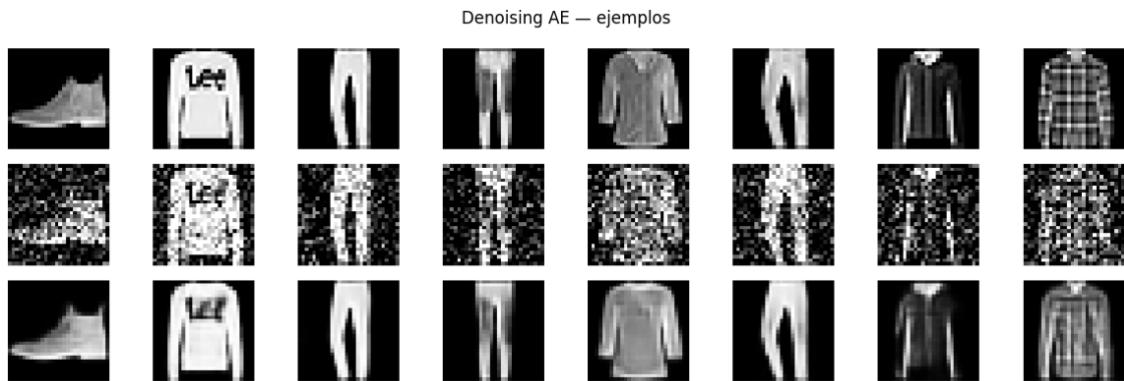
C.3 Denoising Autoencoder con 3 capas para FMNIST

Se crea y entrena un denoising autoencoder (DAE) de 3 capas para FMNIST partiendo de la mejor versión previa de un autoencoder (AE-3L).

C.3.1 Curva PSNR contra σ



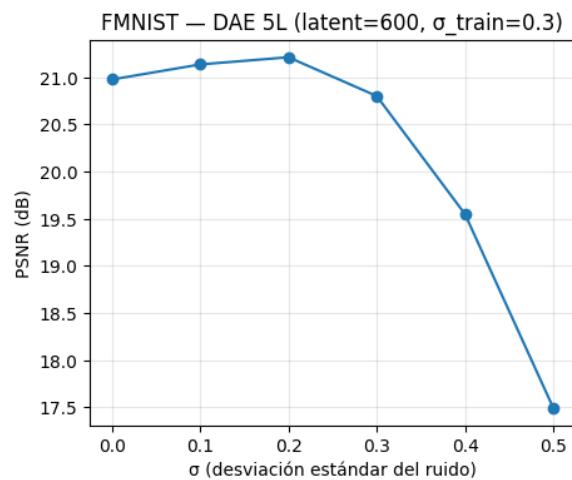
C.3.2 Ejemplos



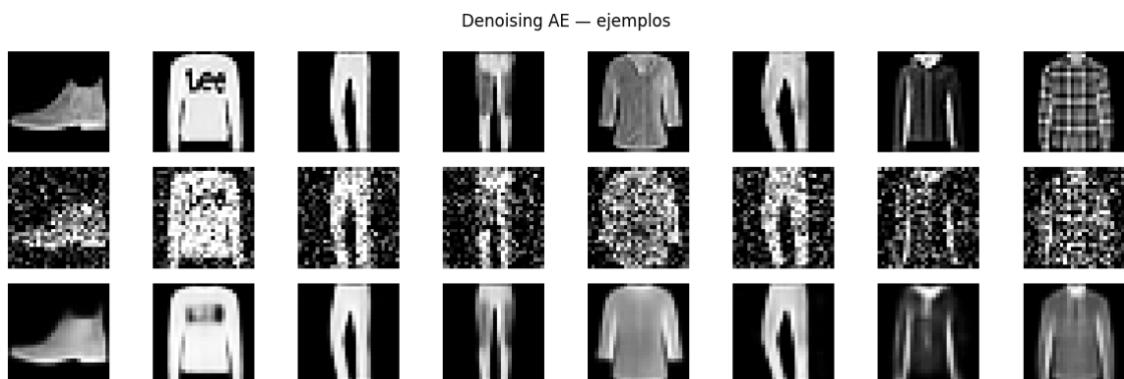
C.4 Denoising Autoencoder con 5 capas para FMNIST

Se crea y entrena un denoising autoencoder (DAE) de 5 capas para FMNIST partiendo de la mejor versión previa de un autoencoder (AE-5L).

C.4.1 Curva PSNR contra σ



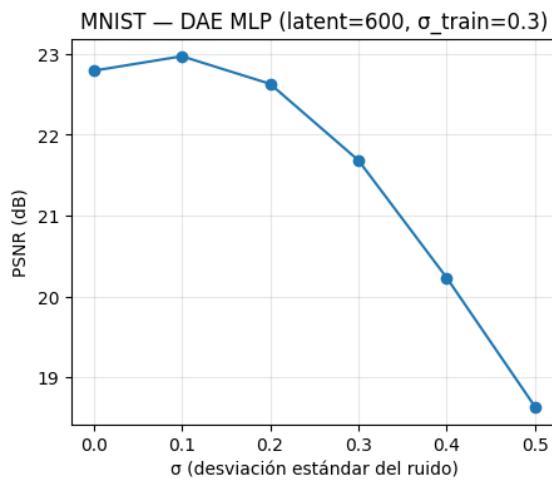
C.4.2 Ejemplos



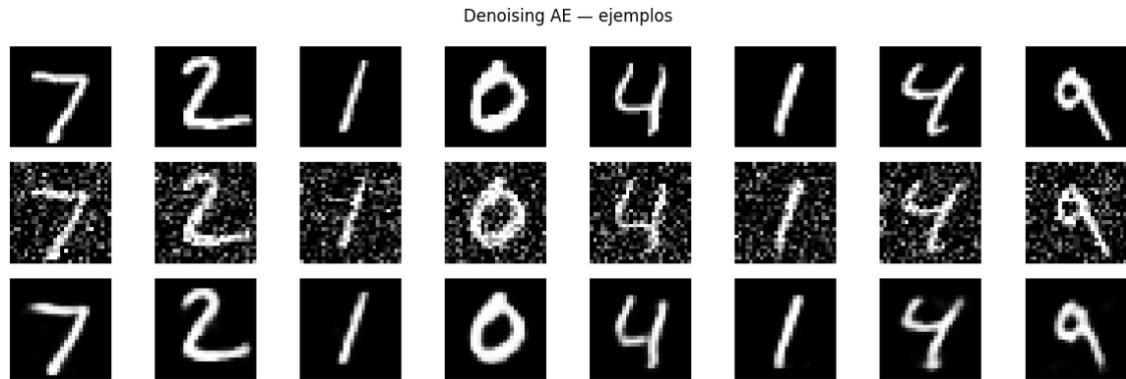
C.5 Denoising Autoencoder con MLP para MNIST

Se crea y entrena un denoising autoencoder (DAE) con MLP para MNIST partiendo de la mejor versión previa de un autoencoder (AE-MLP).

C.5.1 Curva PSNR contra σ



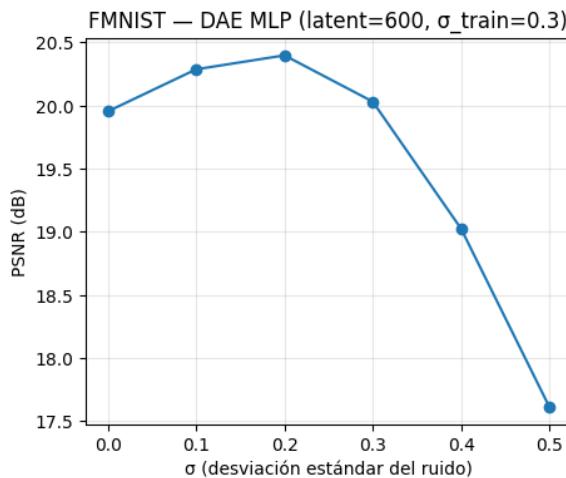
C.5.2 Ejemplos



C.6 Denoising Autoencoder con MLP para FMNIST

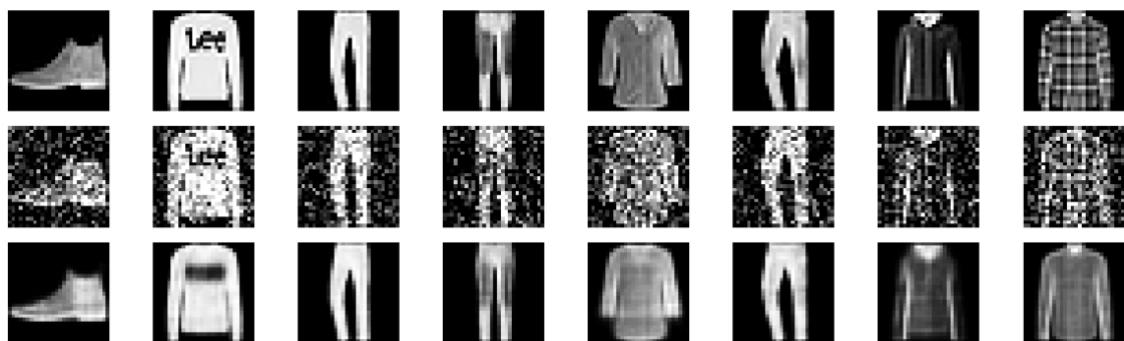
Se crea y entrena un denoising autoencoder (DAE) con MLP para FMNIST partiendo de la mejor versión previa de un autoencoder (AE-MLP).

C.6.1 Curva PSNR contra σ



C.6.2 Ejemplos

Denoising AE — ejemplos



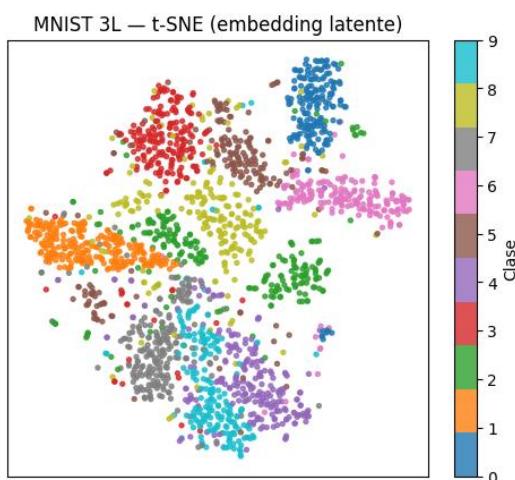
Anexo D: Embeddings con t-SNE y PCA

Se toman hasta 2.000 imágenes del conjunto de prueba y se pasan por el encoder del modelo para obtener sus “huellas” internas (vectores latentes). Con esas huellas y sus etiquetas, se crean dos mapas en 2D: uno con t-SNE (método no lineal) y otro con PCA (método lineal).

D.1 Arquitectura de 3 capas con MNIST

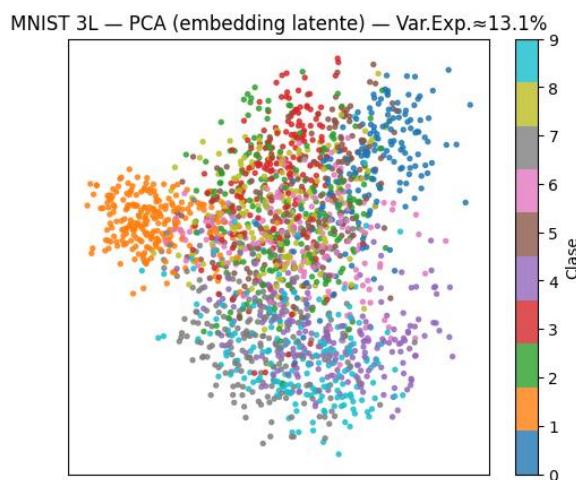
D.1.1 t-SNE (MNIST 3L)

Técnica no lineal que proyecta las representaciones latentes a 2D preservando vecindades locales, para visualizar cómo se agrupan los dígitos por similitud.



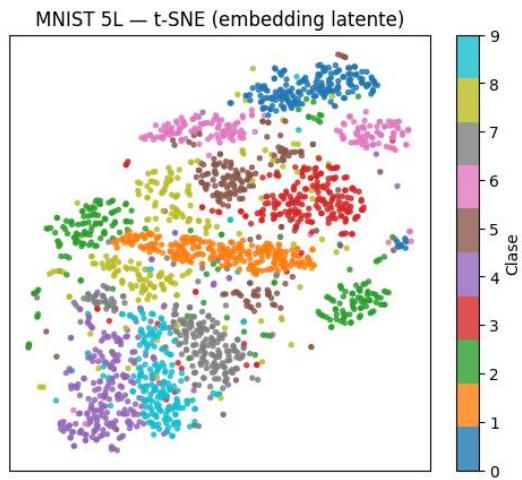
D.1.2 PCA (MNIST 3L)

Método lineal que reduce el embedding a dos componentes principales maximizando la varianza explicada, para observar la estructura global y la separación entre clases.

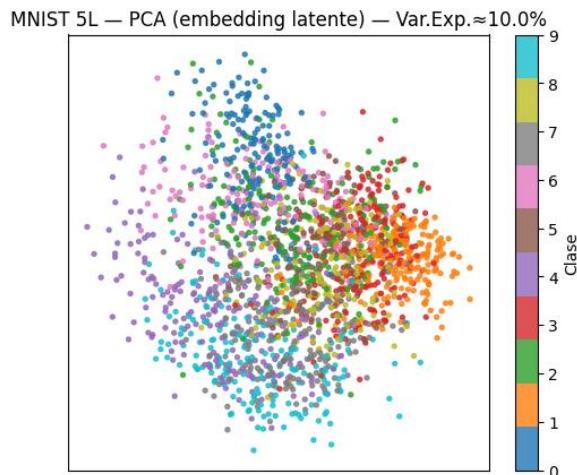


D.2 Arquitectura de 5 capas con MNIST

D.2.1 t-SNE (MNIST 5L)

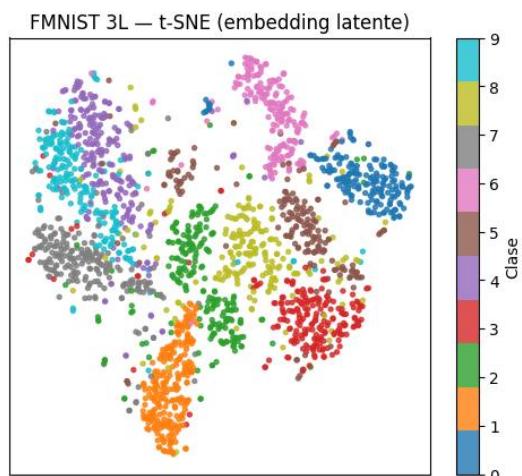


D.2.2 PCA (MNIST 5L)

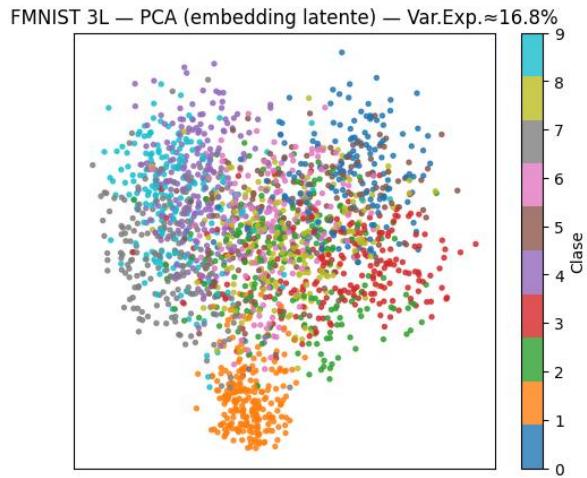


D.3 Arquitectura de 3 capas con FMNIST

D.3.1 t-SNE (FMNIST 3L)

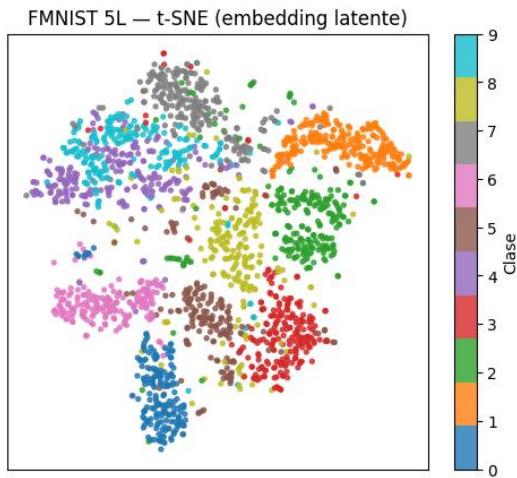


D.3.2 PCA (FMNIST 3L)

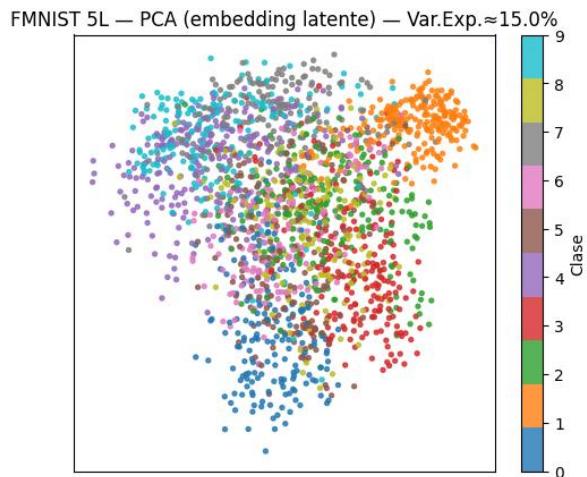


D.4 Arquitectura de 5 capas con FMNIST

D.4.1 t-SNE (FMNIST 5L)

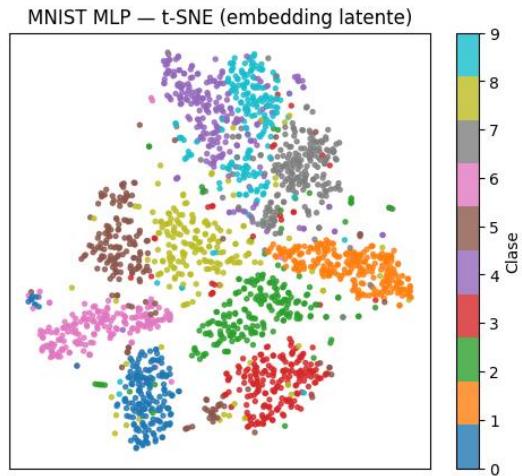


D.4.2 PCA (FMNIST 5L)

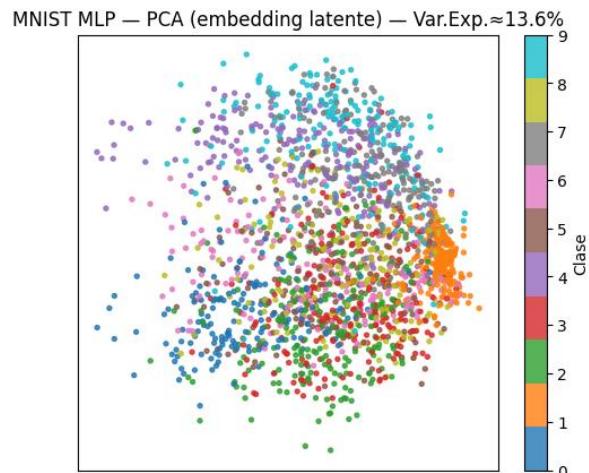


D.5 Arquitectura de MLP con MNIST

D.5.1 t-SNE (MNIST MLP)

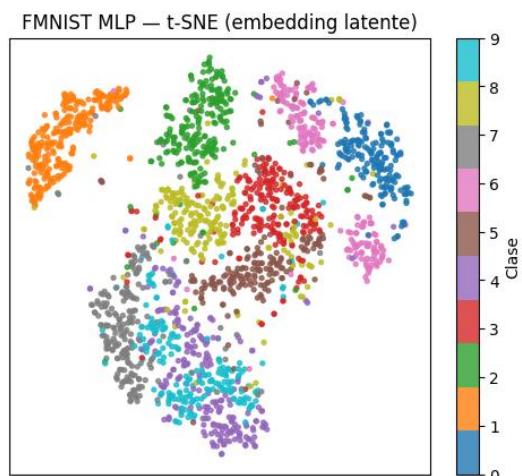


D.5.2 PCA (MNIST MLP)

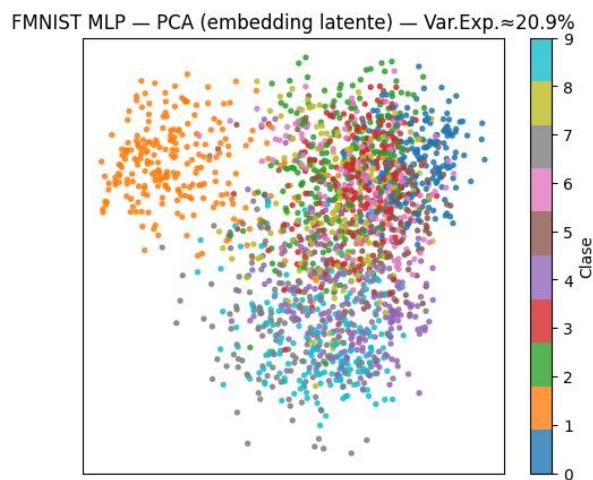


D.6 Arquitectura de MLP con FMNIST

D.6.1 t-SNE (FMNIST MLP)



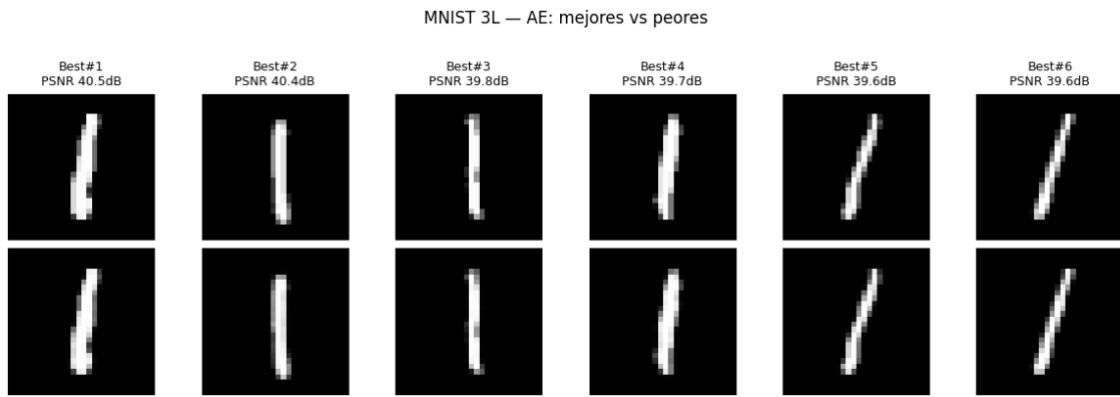
D.6.2 PCA (FMNIST MLP)



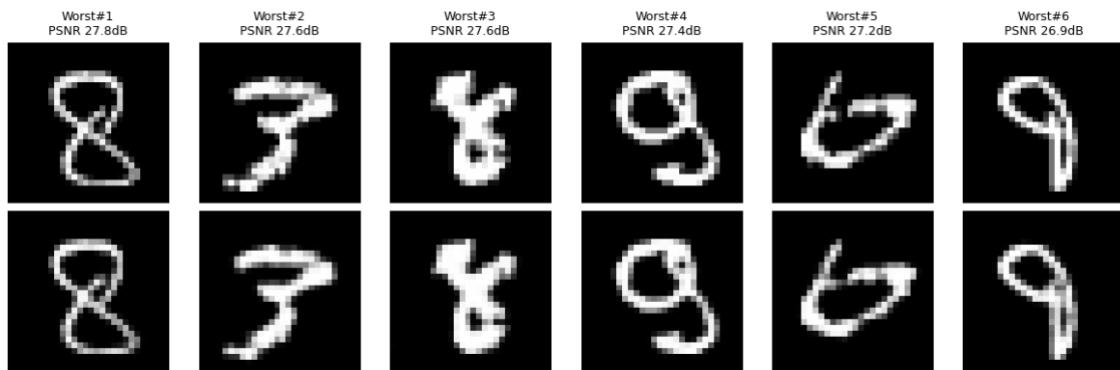
Anexo E: Comparativa de mejores y peores reconstrucciones de las imágenes sin ruido.

E.1 Arquitectura de 3 capas con MNIST

E.1.1 Mejores reconstrucciones

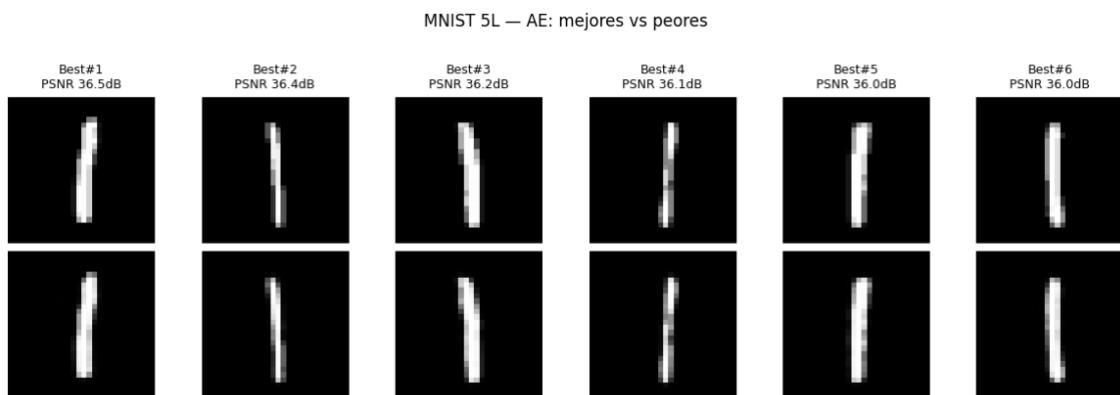


E.1.2 Peores Reconstrucciones

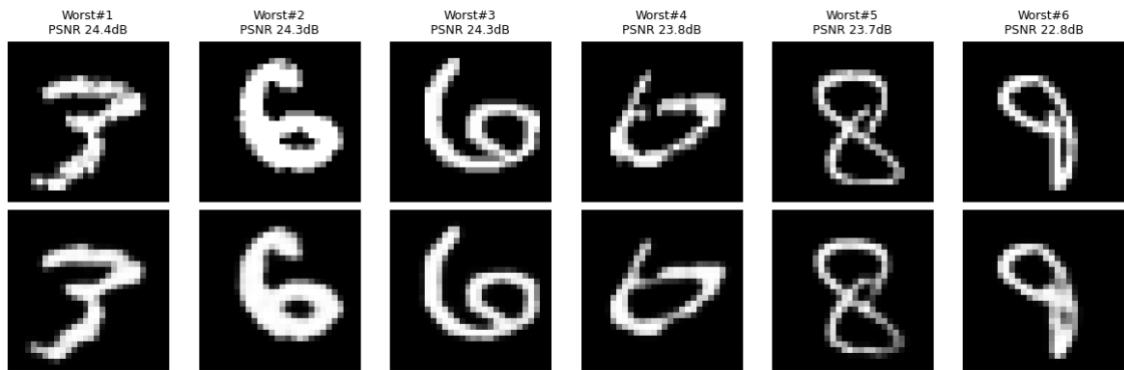


E.2 Arquitectura de 5 capas con MNIST

E.2.1 Mejores reconstrucciones



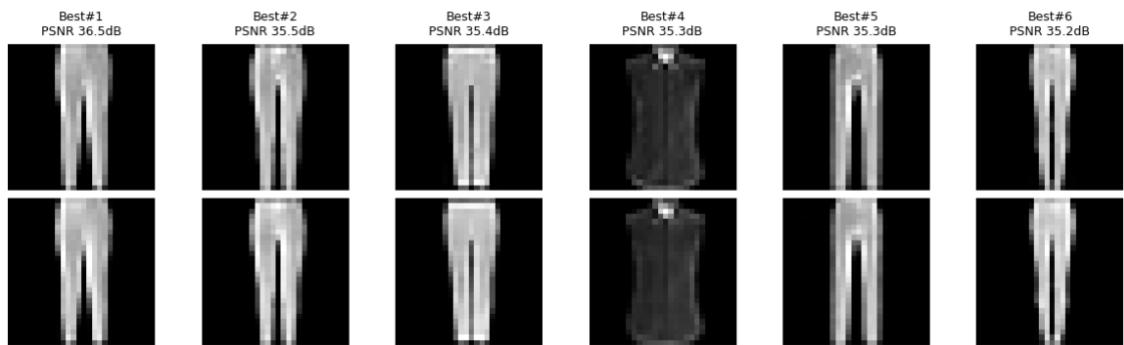
E.2.2 Peores Reconstrucciones



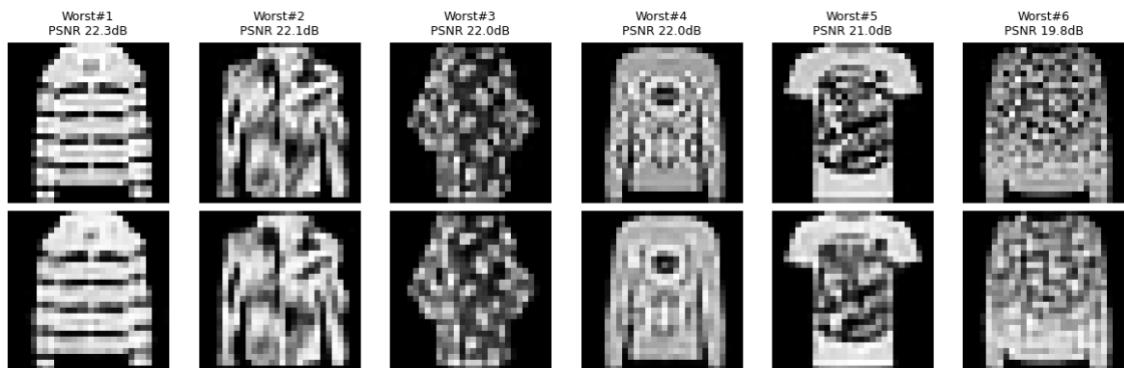
E.3 Arquitectura de 3 capas con FMNIST

E.3.1 Mejores reconstrucciones

FMNIST 3L — AE: mejores vs peores



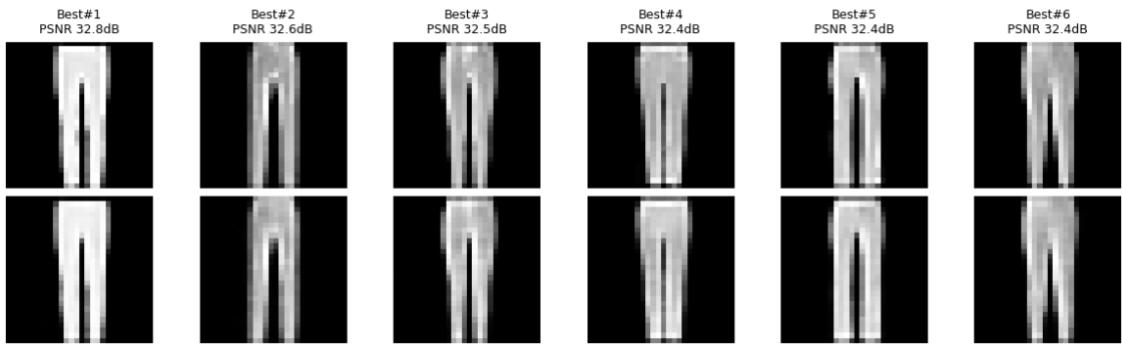
E.3.2 Peores Reconstrucciones



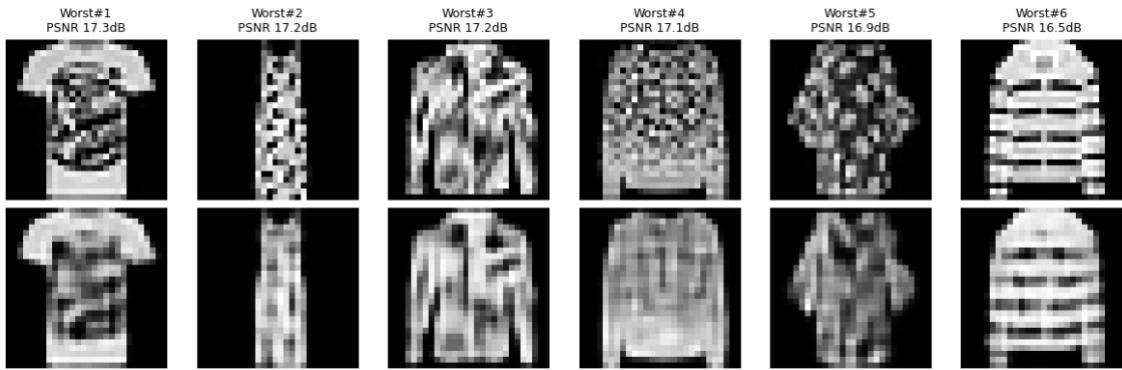
E.4 Arquitectura de 5 capas con FMNIST

E.4.1 Mejores reconstrucciones

FMNIST 5L — AE: mejores vs peores



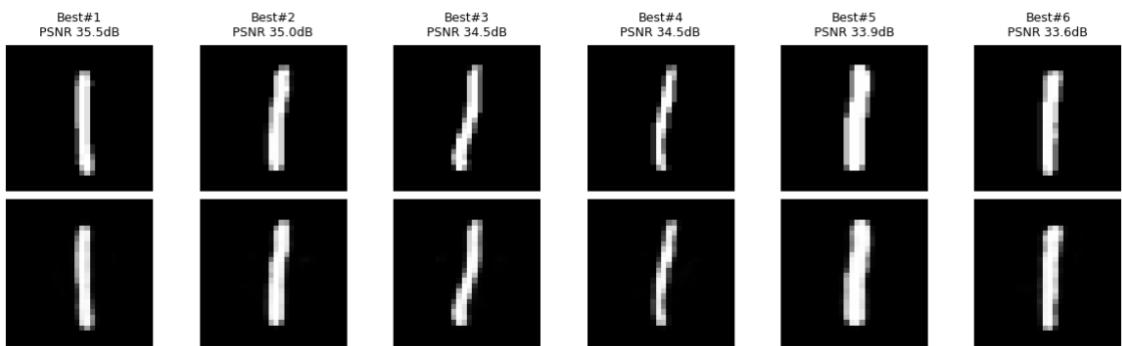
E.4.2 Peores Reconstrucciones



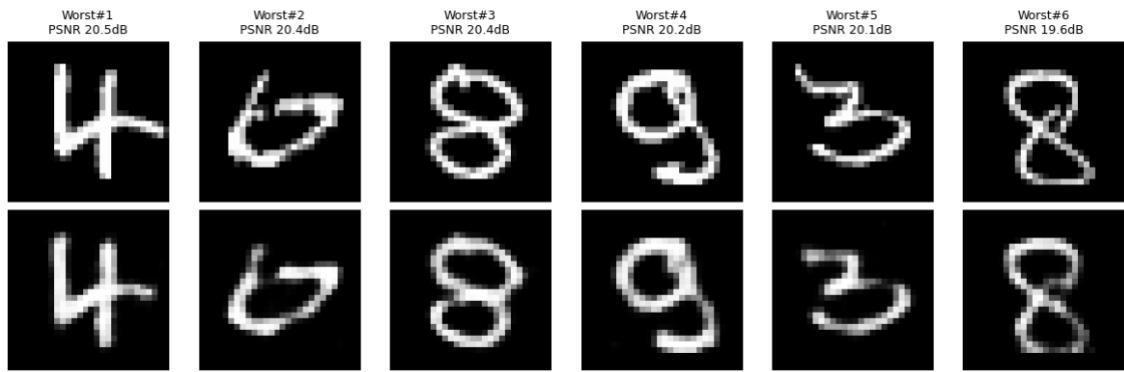
E.5 Arquitectura de MLP con MNIST

E.5.1 Mejores reconstrucciones

MNIST MLP — AE: mejores vs peores

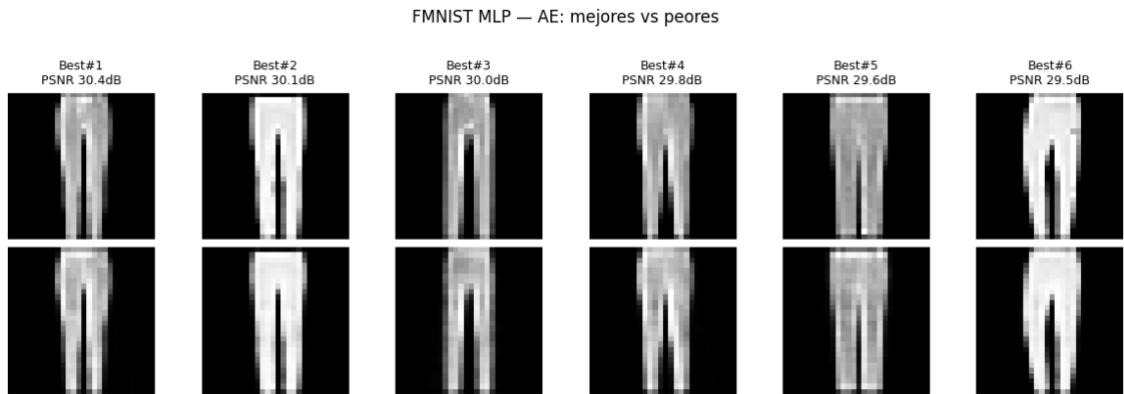


E.5.2 Peores Reconstrucciones

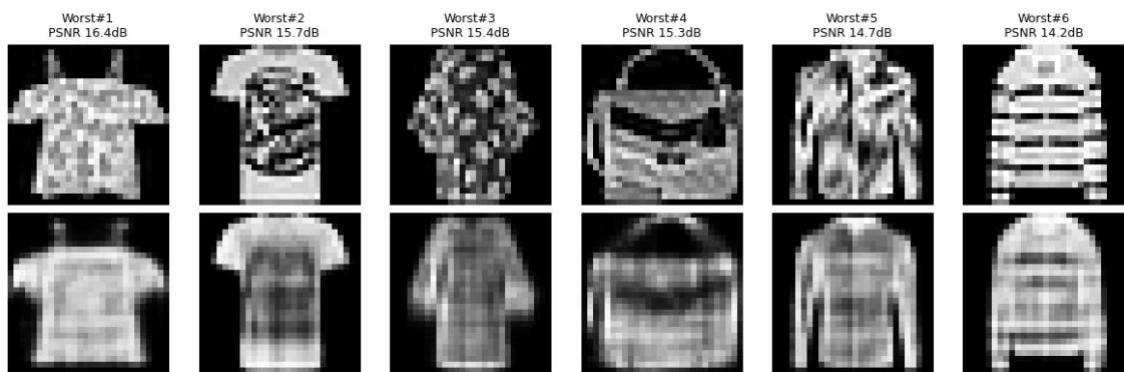


E.6 Arquitectura de MLP con FMNIST

E.6.1 Mejores reconstrucciones



E.6.2 Peores Reconstrucciones

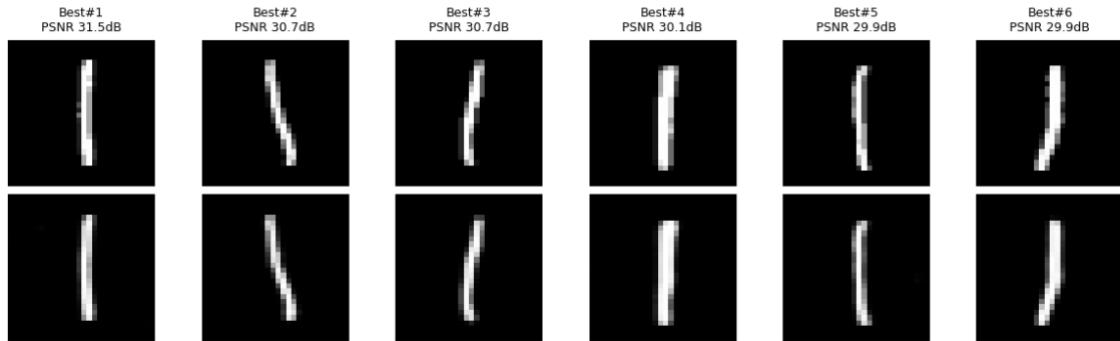


Anexo F: Comparativa de mejores y peores reconstrucciones de las imágenes con ruido.

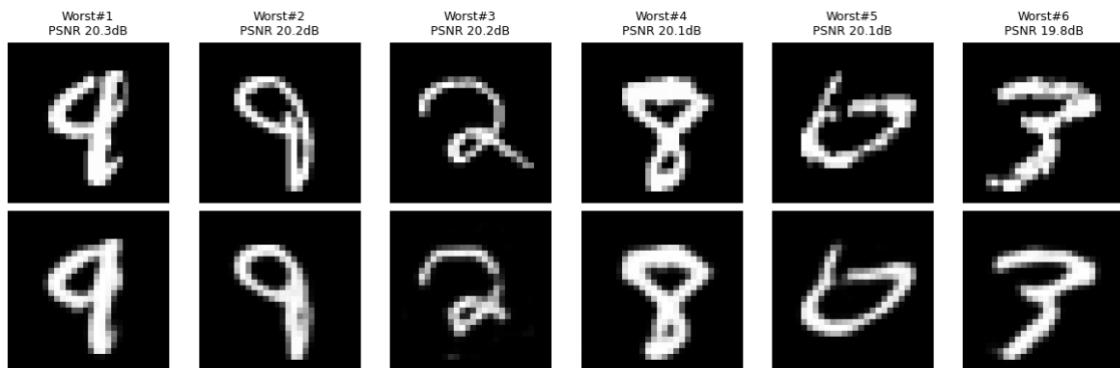
F.1 Arquitectura de 3 capas con MNIST

F.1.1 Mejores reconstrucciones

MNIST 3L — DAE $\sigma=0.3$: mejores vs peores



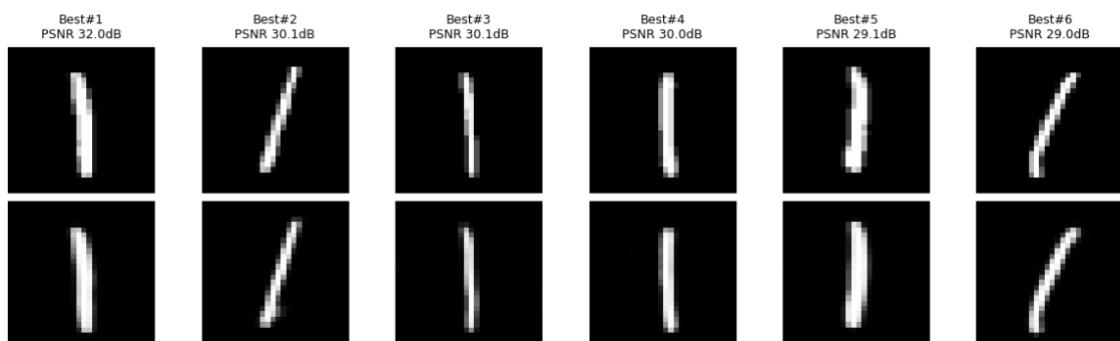
F.1.2 Peores Reconstrucciones



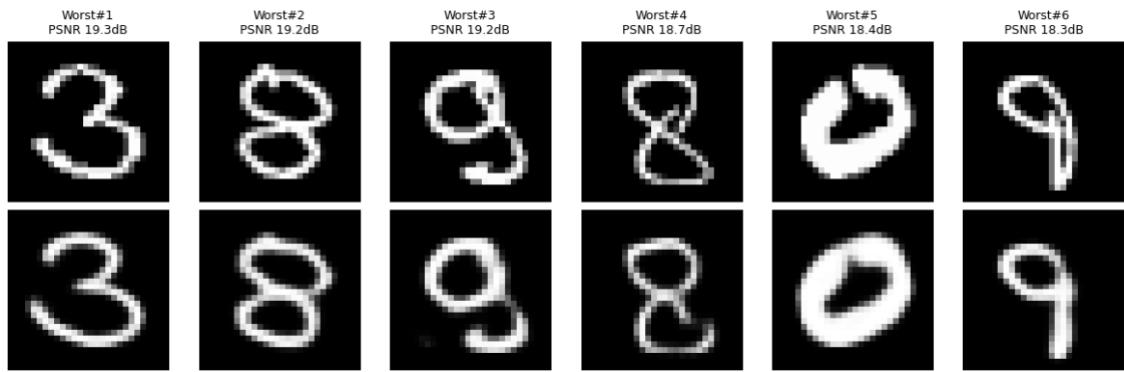
F.2 Arquitectura de 5 capas con MNIST

F.2.1 Mejores reconstrucciones

MNIST 5L — DAE $\sigma=0.3$: mejores vs peores

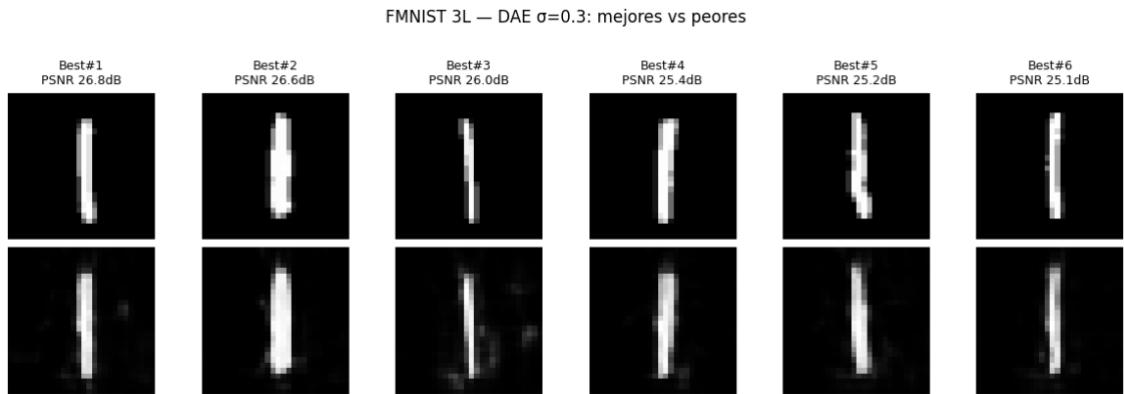


F.2.2 Peores Reconstrucciones

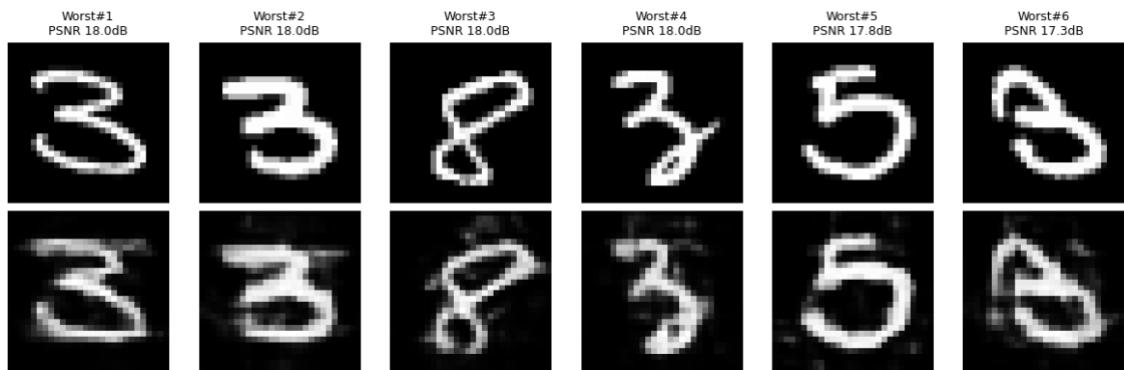


F.3 Arquitectura de 3 capas con FMNIST

F.3.1 Mejores reconstrucciones



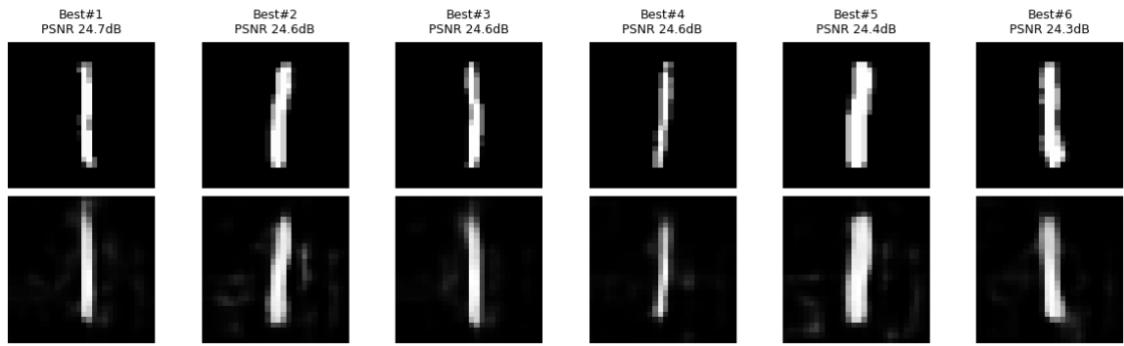
F.3.2 Peores Reconstrucciones



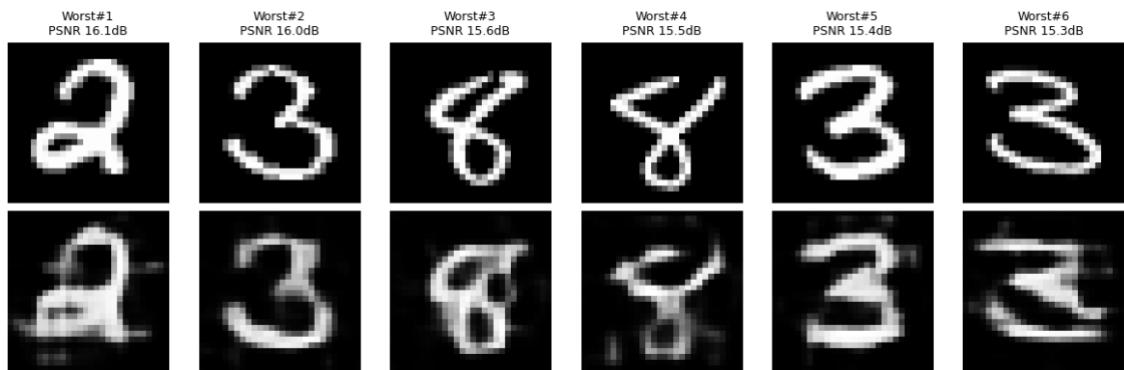
F.4 Arquitectura de 5 capas con FMNIST

F.4.1 Mejores reconstrucciones

FMNIST 5L — DAE $\sigma=0.3$: mejores vs peores



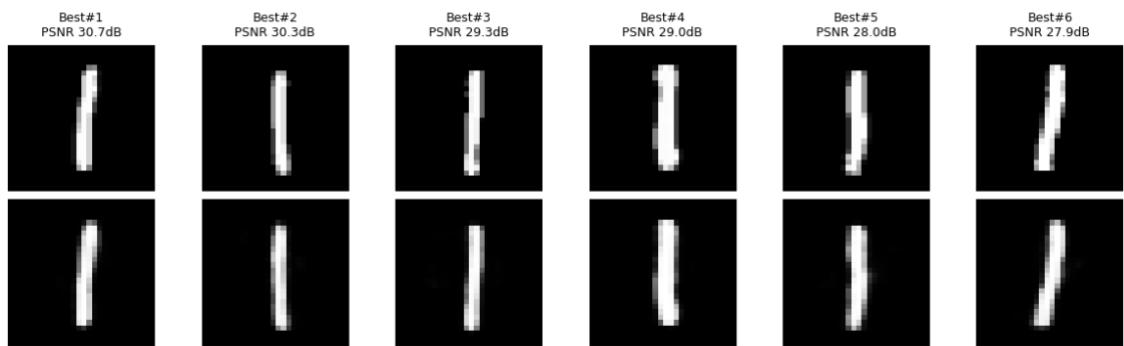
F.4.2 Peores Reconstrucciones



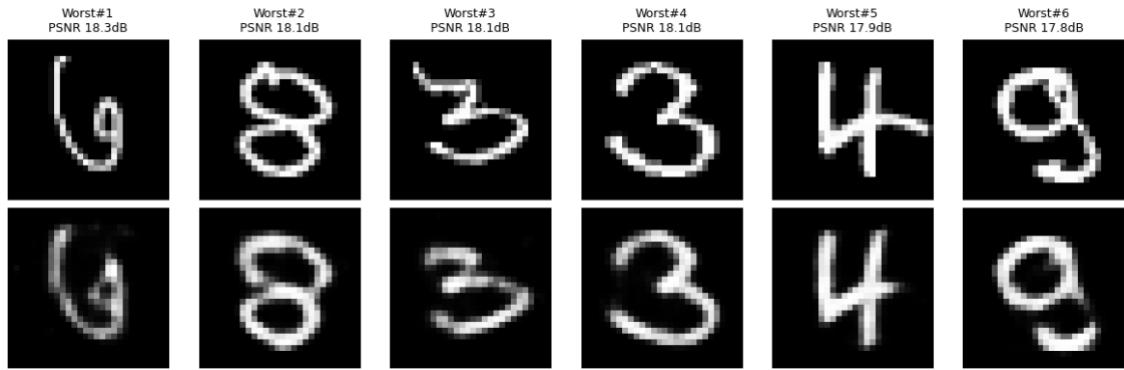
F.5 Arquitectura de MLP con MNIST

F.5.1 Mejores reconstrucciones

MNIST MLP — DAE $\sigma=0.3$: mejores vs peores



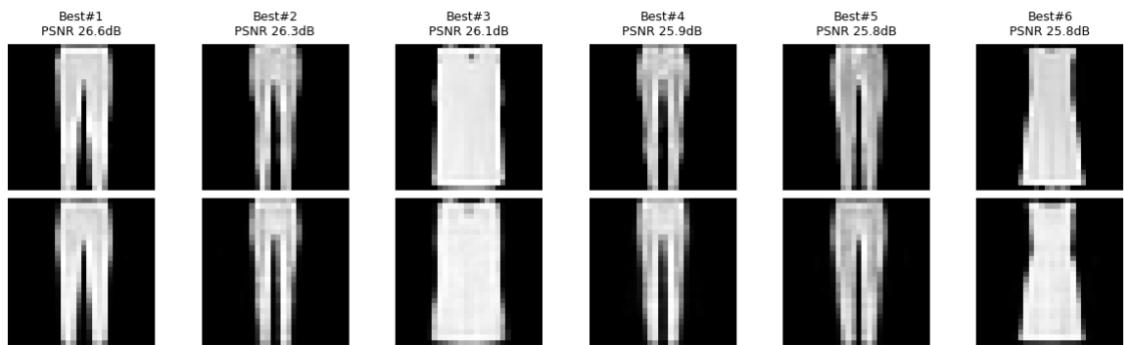
F.5.2 Peores Reconstrucciones



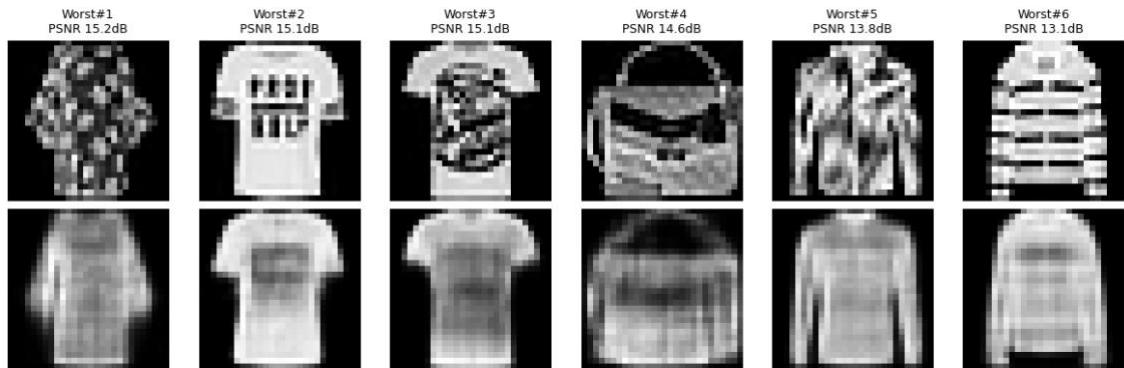
F.6 Arquitectura de MLP con FMNIST

F.6.1 Mejores reconstrucciones

FMNIST MLP — DAE $\sigma=0.3$: mejores vs peores



F.6.2 Peores Reconstrucciones



ANEXO G: Entrenamiento Cruzado (MNIST -> FMNIST y FMNIST -> MNIST)

G.1 Entrenamiento cruzado con la arquitectura convolucional del autoencoder

Entrenamiento	Test	Modelo	PSNR Entrenamiento	PSNR Test
MNIST	FMNIIST	3 capas CNN	34.68 ± 2.46	18.43 ± 2.48
FMNIST	MNIST	3 capas CNN	31.95 ± 2.82	32.31 ± 1.95
MNIST	FMNIST	5 capas CNN	29.95 ± 2.33	15.52 ± 2.47
FMNIST	MNIST	5 capas CNN	27.22 ± 3.05	24.91 ± 1.95

G.2 Entrenamiento cruzado con la arquitectura MLP del autoencoder

Entrenamiento	Test	Modelo	PSNR Entrenamiento	PSNR Test
MNIST	FMNIIST	MLP	27.41 ± 2.56	12.00 ± 3.07
FMNIST	MNIST	MLP	24.41 ± 3.21	18.15 ± 1.85

Anexo H: Uso del decoder como generador de imágenes

Se le añaden al modelo dos cosas:

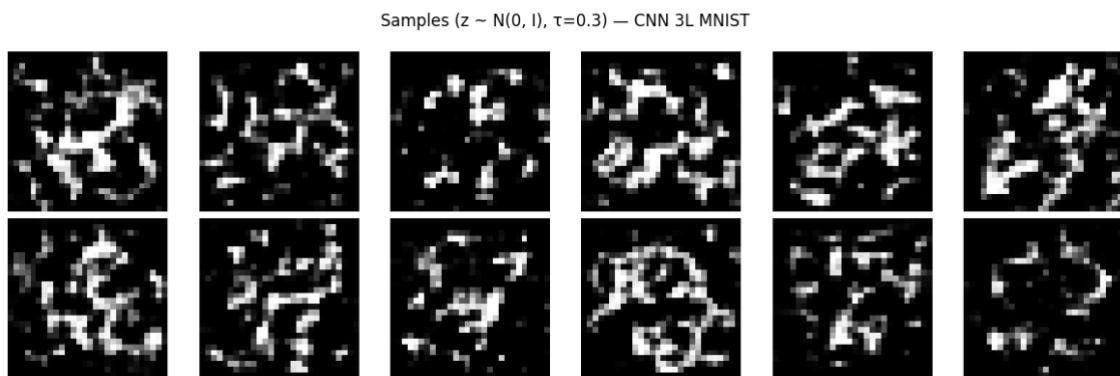
- encode (para convertir una imagen en un vector)
- decode (para convertir un vector en imagen).

Después se crean vectores aleatorios y , con decode, el modelo genera imágenes nuevas a partir de ellos. Por último, esas muestras se dibujan en una cuadrícula para ver rápidamente qué tipo de imágenes es capaz de producir cada modelo.

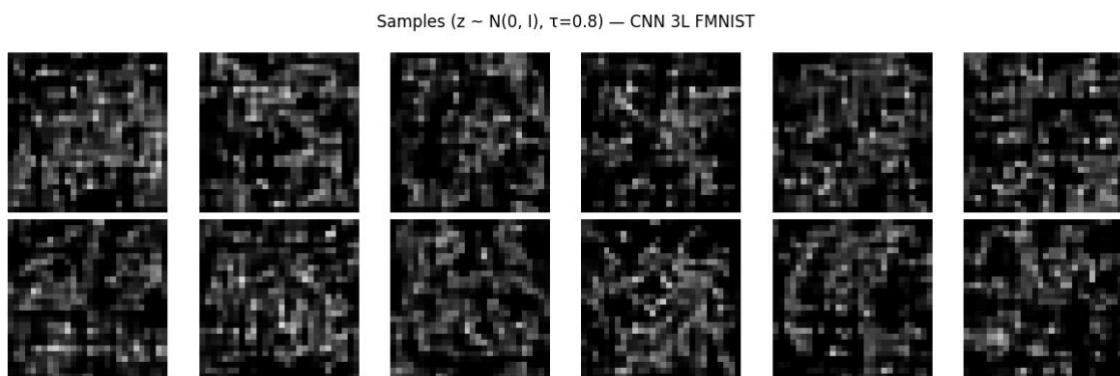
H.1 Imágenes sintetizadas a partir de ruido gaussiano estándar

En esta estrategia se generan vectores latentes aleatorios desde una normal estándar y se decodifican para producir imágenes.

H.1.1 Arquitectura de 3 capas con MNIST

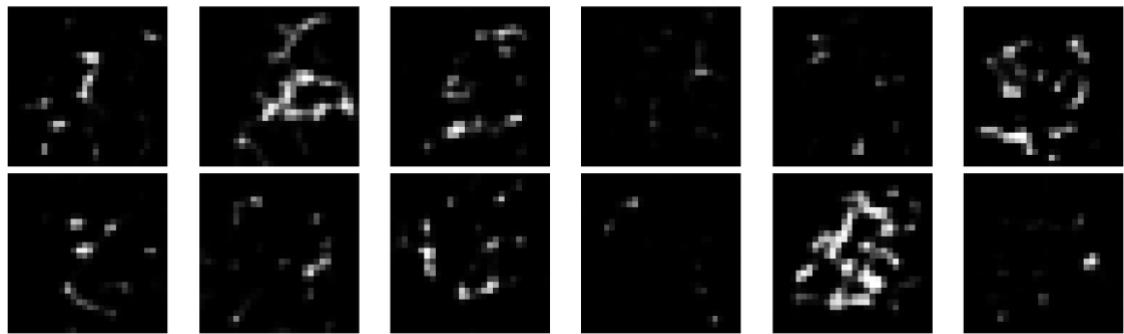


H.1.2 Arquitectura de 3 capas con FNIST



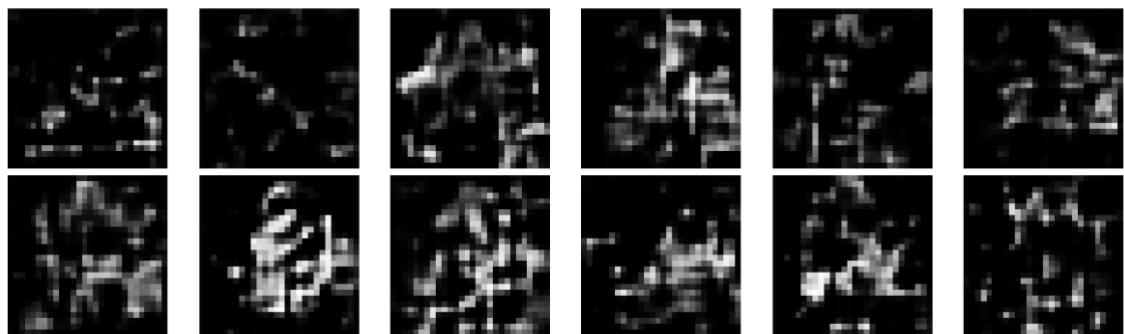
H.1.3 Arquitectura de 5 capas con MNIST

Samples ($z \sim N(0, I)$, $\tau=0.8$) — CNN 5L MNIST



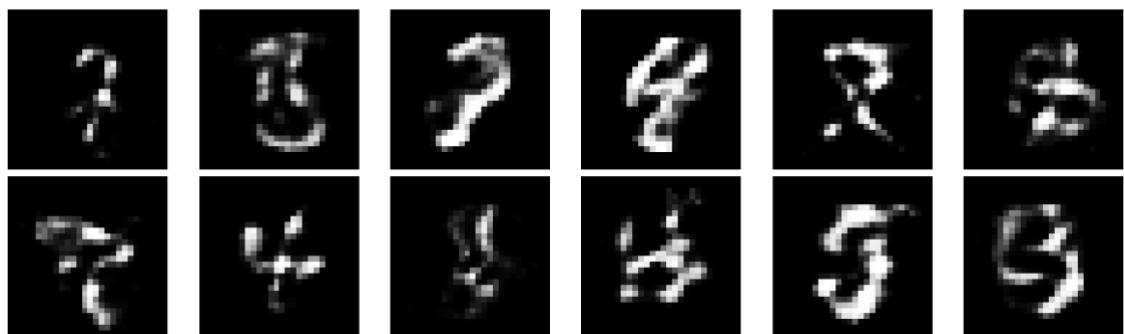
H.1.4 Arquitectura de 5 capas con FMNIST

Samples ($z \sim N(0, I)$, $\tau=0.8$) — CNN 5L FMNIST



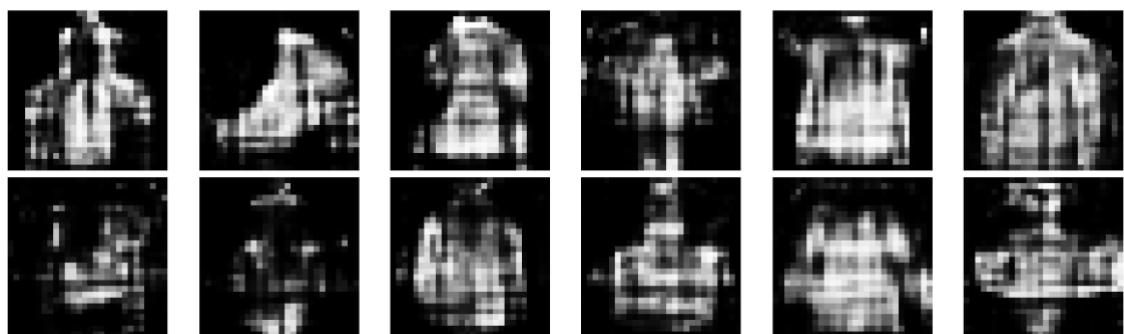
H.1.5 Arquitectura de MLP con MNIST

Samples ($z \sim N(0, I)$, $\tau=0.8$) — MLP



H.1.6 Arquitectura de MLP con FMNIST

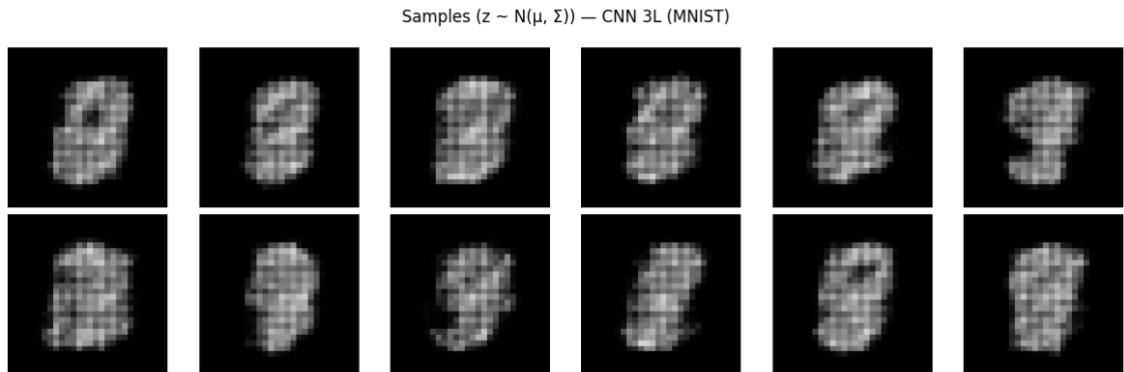
Samples ($z \sim N(0, I)$, $\tau=0.8$) — MLP



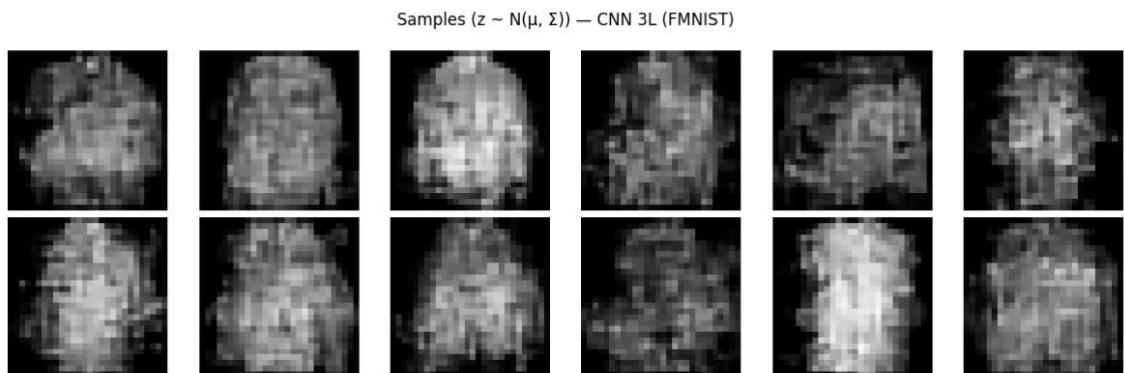
H.2 Imágenes sintetizadas desde la gaussiana latente aprendida

Primero se estima, a partir de datos reales, la media y desviaciones del latente; luego se muestrea alrededor de esa distribución.

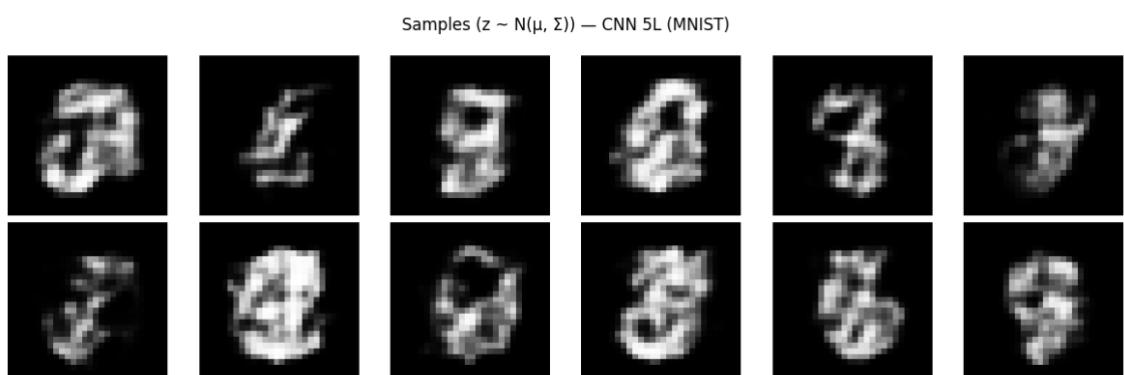
H.2.1 Arquitectura de 3 capas con MNIST



H.2.2 Arquitectura de 3 capas con FMNIST

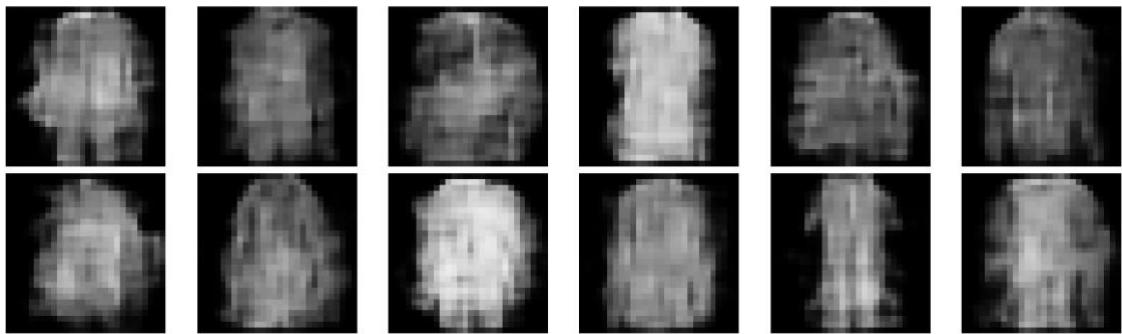


H.2.3 Arquitectura de 5 capas con MNIST



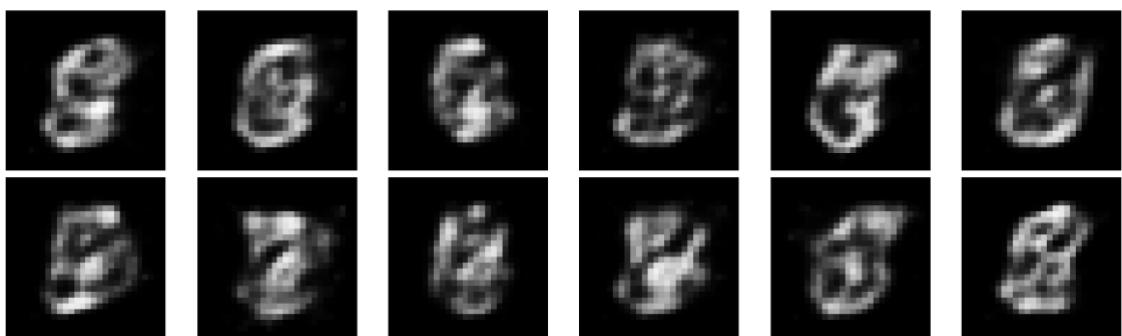
H.2.4 Arquitectura de 5 capas con FMNIST

Samples ($z \sim N(\mu, \Sigma)$) — CNN 5L (FMNIST)



H.2.5 Arquitectura de MLP con MNIST

Samples ($z \sim N(\mu, \Sigma)$) — MLP (MNIST)



H.2.6 Arquitectura de MLP con FMNIST

Samples ($z \sim N(\mu, \Sigma)$) — MLP (FMNIST)

